

MASCHINELLES LERNEN

EINE ANALYSE ZU KOMPETENZEN, FORSCHUNG UND ANWENDUNG



FRAUNHOFER-GESELLSCHAFT

MASCHINELLES LERNEN

EINE ANALYSE ZU KOMPETENZEN, FORSCHUNG UND ANWENDUNG

Autoren

Inga Döbel | Fraunhofer IMW
Dr. Miriam Leis | Fraunhofer-Zentrale
Manuel Molina Vogelsang | Fraunhofer IMW
Dmitry Neustroev | Fraunhofer IMW
Dr. Henning Petzka | Fraunhofer IAIS
Annamaria Riemer | Fraunhofer IMW
Dr. Stefan Rüping | Fraunhofer IAIS
Dr. Angelika Voss | Fraunhofer IAIS
Martin Wegele | Fraunhofer-Zentrale
Dr. Juliane Welz | Fraunhofer IMW

in Kooperation mit

Forschungszentrum Maschinelles Lernen im Fraunhofer-
Cluster of Excellence Cognitive Internet Technologies
Fraunhofer-Allianz Big Data & Künstliche Intelligenz

Die Publikation wurde durch das Bundesministerium
für Bildung und Forschung (BMBF) gefördert.

GEFÖRDERT VOM



Bundesministerium
für Bildung
und Forschung

INHALT

Vorwort	5
Executive Summary	6
1 Konzepte, Methoden und Grenzen des Maschinellen Lernens	8
1.1 Maschinelles Lernen und Künstliche Intelligenz	8
1.2 Ein kurzer historischer Überblick	9
1.3 Lernaufgaben, Lernstile, Modelle und Algorithmen	10
1.4 Tiefe Neuronale Netze	11
1.5 Herausforderungen des Maschinellen Lernens	11
2 Akteure und Kompetenzlandschaft	13
2.1 Publikationen	14
2.2 Patente	20
3 Märkte und Branchen	24
3.1 Techniken in der Anwendung	24
3.2 Anwendungsbranchen und Produkte	25
4 Neue Aufgaben für die Forschung	28
4.1 Daten als Herausforderung	29
4.1.1 Nutzung großer Datenmengen	29
4.1.2 Lernen mit geringen Datenmengen	29
4.2 Ausbau der Fähigkeiten	29
4.2.1 Anpassungsfähigkeit und Flexibilität	29
4.2.2 Lernen mit zusätzlichem Wissen	30
4.2.3 Kollaboration	30
4.3 Nachvollziehbarkeit, Fairness und Sicherheit	30
4.3.1 Nachvollziehbarkeit, Erklärbarkeit und Transparenz	30
4.3.2 Fairness und Diskriminierungsfreiheit	31
4.3.3 Sicherheit und robuste Lernverfahren	31

5	Fähigkeiten und Reifegrade	32
6	Rahmenbedingungen für Maschinelles Lernen	38
6.1	Aus- und Weiterbildung	38
6.2	Transfer in die Praxis	38
6.3	Datenverfügbarkeit und Governance	39
6.4	Rechtliche, ethische und soziale Gestaltung	40
7	Fazit	42
	Glossar	43
	Quellenverzeichnis	47
	Weiterführende Literatur zum Thema Maschinelles Lernen	50
	Abbildungen und Tabellen	51
	Danksagung	52
	Impressum	53

VORWORT

Neueste Errungenschaften im Bereich des Maschinellen Lernens (ML) haben einen enormen Beitrag zur Weiterentwicklung von Künstlicher Intelligenz (KI) und kognitiven Systemen geleistet. KI ist inzwischen zu einem globalen wirtschaftlich und strategisch hochrelevanten Faktor geworden. In Zukunft werden Menschen in vielen Kontexten lernenden Systemen begegnen. Es gibt kaum einen Bereich, der nicht von ML- und KI-basierten Technologien entscheidend transformiert wird: sei es die Produktion von Gütern im Kontext Industrie 4.0, das Gesundheitswesen mit KI-Assistenten für eine bessere Diagnostik, unsere Mobilität mit autonomen Fahrzeugen oder eine saubere und sichere Energieversorgung, wo intelligente Computerprogramme eine optimale Steuerung gewährleisten. Aber auch unsere Ausbildung und Arbeitswelt werden zusehends von intelligenten Systemen geprägt sein, die uns helfen können und die von uns lernen.

Deutschland bringt im Bereich der ML- und KI-Forschung sehr gute Voraussetzungen mit und hat frühzeitige Pionierarbeit – beispielsweise auf dem Gebiet der immer noch relevanten Stützvektormaschinen – geleistet. Gleichwohl muss uns hier noch eine stärkere und schnellere anwendungsnahe Umsetzung von KI in konkrete Produkt-, Prozess- und Dienstleistungsinnovationen gelingen. Der globale Wettbewerb ist enorm stark, insbesondere von ostasiatischer und nordamerikanischer Seite. Deutschland und Europa müssen der Konkurrenz eigene Innovationen entgegensetzen. Nicht zuletzt, weil wir dadurch mittelbar auch eine auf unserem Rechts- und Wertesystem basierte KI in die Anwendung bringen.

Um das Wertschöpfungspotenzial von ML und KI zu nutzen und dem hohen Fachkräftemangel zu begegnen, bedarf es auch einer zielgerichteten und interdisziplinären Aus- und

Weiterbildung in entsprechenden Bereichen, wie beispielsweise »Data Science«. Nur so können Deutschland und Europa im internationalen Wettbewerb um kluge Köpfe und Talente mithalten.

Wichtig ist aber auch eine faktenbasierte Auseinandersetzung in der Breite zu den Einsatzmöglichkeiten und der Gestaltung von KI- und ML-basierten Technologien, wie sie beispielsweise in der Plattform Lernende Systeme angelegt ist. Ängsten und Mythen ebenso wie übersteigerten Erwartungen müssen wissenschaftliche Erkenntnisse entgegengesetzt werden.

Die vorliegende Publikation – basierend auf den Ergebnissen eines aktuellen Forschungsprojekts im Auftrag des BMBF – liefert einen wichtigen Beitrag zur öffentlichen Debatte. Sie ordnet wesentliche Begriffe des Maschinellen Lernens wissenschaftlich ein, gibt einen Überblick zu aktuellen Herausforderungen und künftigen Forschungsaufgaben und stellt Deutschlands Position in der Anwendung von Maschinellen Lernen dar.

Den Leserinnen und Lesern dieser Ergebnisbroschüre wünsche ich viele interessante Einblicke. Auf den weiteren Austausch zu den Potenzialen und Auswirkungen von KI-basierten Produkten und Dienstleistungen freue ich mich sehr.



Prof. Dr.-Ing. Reimund Neugebauer
Präsident der Fraunhofer-Gesellschaft e. V.

EXECUTIVE SUMMARY

Kaum ein anderes Forschungsfeld hat in letzter Zeit so viel Aufsehen erregt wie das Maschinelle Lernen (ML) mit den damit einhergehenden rasanten Fortschritten auf dem Gebiet der Künstlichen Intelligenz (KI).

Diese Publikation gibt eine kompakte Einführung in die wichtigsten Konzepte und Methoden des Maschinellen Lernens, einen Überblick über Herausforderungen und neue Forschungsfragen sowie eine Übersicht zu Akteuren, Anwendungsfeldern und sozioökonomischen Rahmenbedingungen der Forschung mit Fokus auf den Standort Deutschland. Die Basis hierfür ist das vom BMBF geförderte wissenschaftliche Projekt »Maschinelles Lernen – Kompetenzen, Anwendungen und Forschungsbedarf«, das vom Fraunhofer-Institut für Intelligente Analyse- und Informationssysteme IAIS, dem Fraunhofer-Zentrum für Internationales Management und Wissensökonomie IMW sowie der Zentrale der Fraunhofer-Gesellschaft durchgeführt wurde. Neben der statistischen Auswertung von wissenschaftlichen Publikationen, Patenten und Projekten wurden zahlreiche Marktstudien und wissenschaftliche Publikationen analysiert sowie Interviews mit 18 Expertinnen und Experten auf dem Gebiet des ML durchgeführt, ebenso wie ein Workshop mit 17 Fachleuten aus Wissenschaft, Wirtschaft und Politik.

In Expertenkreisen wird ML als Schlüsseltechnologie für moderne KI-Techniken gesehen, weshalb insbesondere im ökonomischen Kontext KI und ML oft synonym verwendet werden. Maschinelles Lernen und insbesondere das sogenannte Deep Learning (DL) eröffnen völlig neue Möglichkeiten in der automatischen Sprachverarbeitung, Bildanalyse, medizinischen Diagnostik, Prozesssteuerung und dem Kundenmanagement. Wirtschaftsmedien sprachen 2017 vom »Jahr der KI« und die Anwendungsmöglichkeiten werden mit dem Fortschreiten der Digitalisierung weiter steigen.

Die wissenschaftliche ML-Forschung ist längst nicht ausgeschöpft und insbesondere Forschungsfragen zu ML mit extrem großen oder sehr kleinen Datenmengen, zur Kombination von ML mit physikalischem oder Expertenwissen sowie Sicherheit und Transparenz von ML-Modellen sind hochaktuell und hochrelevant.

Statistiken zu Publikationen in wissenschaftlichen Fachzeitschriften zeigen, dass 60 % aller Publikationen zu ML aus China, den USA, der EU und Indien kommen. China weist hier ein besonders hohes quantitatives Wachstum von jährlich 17,5 % im Zeitraum 2006 bis 2016 auf. Sechs der zehn meist publizierenden Hochschulen und Forschungseinrichtungen kommen aus China. 51 % der erfassten Publikationen können dem Anwendungsfeld der Bild- und Videoauswertung zugeordnet werden, gefolgt von 18 % zur Sprachverarbeitung. Bei den Publikationen zum Deep Learning kann seit 2013 weltweit ein merkbarer Anstieg verzeichnet werden. Davor war der Anteil vernachlässigbar gering, und auch 2016 ist er mit 2,6 % in Fachzeitschriften und 6,8 % in Konferenzbeiträgen geringer als erwartet.

In Europa entfallen die meisten Publikationen auf Großbritannien, gefolgt von Deutschland. Innerhalb von Deutschland gibt es jedoch regionale Unterschiede. Die Bundesländer mit der höchsten Publikations- und Patendichte sind Baden-Württemberg, Bayern und Nordrhein-Westfalen.

In unserer Patentrecherche als Indikator für die technologische Leistungsfähigkeit von Regionen und Einrichtungen entfallen die Hauptaktivitäten auf die USA, China und Südkorea. 73 % aller im Zeitraum 2006 bis 2016 erfassten Patente stammen aus diesen Ländern, mit den Unternehmen Microsoft, Google, Amazon, Facebook, Samsung (Südkorea) und Huawei (China) an der Spitze. In Deutschland sind die patentstärksten Akteure die Siemens AG, Robert Bosch GmbH, Deutsche Telekom AG, Daimler AG, BMW AG und SAP SE. Deutsche mittelständische Unternehmen mit 49 bis 249 Mitarbeitenden weisen vergleichsweise wenige Patentaktivitäten auf. Im Hinblick auf die Standorte von KI-Start-ups ist Berlin, wo über 50 Unternehmen ihren Sitz haben, nach London die zweitstärkste Region in Europa.

Um den Standort Deutschland international zu stärken, haben die konsultierten Fachleute ausdrücklich auf die Aus- und Weiterbildungssituation hingewiesen. Ihnen zufolge muss in Deutschland noch viel stärker ML-bezogen aus- und weitergebildet werden, nicht nur in der Informatik, sondern auch in den Anwendungsdisziplinen. Gleichzeitig sollten Aus- und Weiterbildungsangebote stärker interdisziplinär orientiert sein.

um KI-basierte Kompetenzen in der beruflichen Breite aufzubauen. Zusätzlich müssen entsprechende Arbeitskräfte global angeworben werden, was angesichts des weltweiten Wettbewerbs um Talente sowie der zu erwartenden steigenden Nachfrage nach ML-basierten Produkten und Dienstleistungen eine Herausforderung darstellt.

Deutschland verfügt über eine gute wissenschaftliche Basis in ML. Für die Sicherung der Wettbewerbsfähigkeit ist ausschlaggebend, den Anwendungsbezug in der Forschung zu stärken und dies beispielsweise auch in öffentlichen Forschungsausschreibungen stärker einzufordern. Ferner wurde konstatiert, dass derzeitige Maßnahmen zur Unternehmensförderung eher junge Start-ups anstatt etablierte Traditionsunternehmen ansprechen. Im Hinblick auf die Förderung der Anwendung von ML in Deutschland liegt gerade hier viel Potenzial, insofern sollten KMU durch mehr Fachinformationen zum Einsatz und zur Nutzung von ML unterstützt werden.

Der Zugang zu hinreichend großen und qualitativ hochwertigen Datenbeständen wurde für den Erfolg und die Wettbewerbsfähigkeit Deutschlands als bislang ungelöste

Herausforderung gesehen, insbesondere in der Medizin und der industriellen Produktion. Hier sind Governance-Strukturen, die den kontrollierbaren und sicheren Datenaustausch ermöglichen, sowie datenschutzrechtliche Bedingungen zu berücksichtigen oder anzupassen.

In Zukunft werden Maschinen zusehends entscheidungsrelevante Ergebnisse generieren. Hierzu ist es wichtig, auf der technologischen Seite die Sicherheit, Robustheit und hinreichende Nachvollziehbarkeit von automatisierten Entscheidungsprozessen zu gewährleisten. Gleichzeitig muss dafür gesorgt werden, dass ML-Anwendungen mit juristischen Fragen wie Haftung und Verantwortlichkeit für algorithmisch getroffene Entscheidungen vereinbar und auch technisch umsetzbar sind. Dies auszuformulieren und regulativ umzusetzen ist ein wichtiges und komplexes Anliegen, das einen inter- und transdisziplinären Ansatz erfordert. Für die weitere Verbreitung maschinell basierter Lernverfahren in die Anwendung ist nicht zuletzt auch die gesellschaftliche Akzeptanz von zentraler Bedeutung. Hierfür ist eine breite öffentliche Diskussion und Einbindung verschiedener gesellschaftlicher Gruppen erforderlich.

1 KONZEPTE, METHODEN UND GRENZEN DES MASCHINELLEN LERNENS

1.1 Maschinelles Lernen und Künstliche Intelligenz

In Expertenkreisen wird Maschinelles Lernen als Schlüsseltechnologie der Künstlichen Intelligenz verstanden. Künstliche Intelligenz ist ein Teilgebiet der Informatik mit dem Ziel, Maschinen zu befähigen, Aufgaben »intelligent« auszuführen. Dabei ist weder festgelegt, was »intelligent« bedeutet, noch welche Techniken zum Einsatz kommen. Erste kommerziell bedeutende Erfolge im Bereich der KI erzielten sogenannte Expertensysteme mit manuell konstruierter Wissensbasis. Mit derartigen manuellen Wissensangaben oder gar der expliziten Programmierung eines Lösungswegs ist man bei komplexeren Aufgaben der KI jedoch gescheitert. Eine Alternative hierzu bietet das Maschinelle Lernen, das heute tatsächlich die Schlüsseltechnologie intelligenter Systeme darstellt.

Maschinelles Lernen bezweckt die Generierung von »Wissen« aus »Erfahrung«, indem Lernalgorithmen aus Beispielen ein komplexes Modell entwickeln. Das Modell, und damit die automatisch erworbene Wissensrepräsentation, kann anschließend auf neue, potenziell unbekannte Daten derselben Art angewendet werden. Immer wenn Prozesse zu kompliziert sind, um sie analytisch zu beschreiben, aber genügend viele Beispieldaten – etwa Sensordaten, Bilder oder Texte – verfügbar sind, bietet sich Maschinelles Lernen an. Mit den gelernten Modellen können Vorhersagen getroffen oder Empfehlungen und Entscheidungen generiert werden – ganz ohne im Vorhinein festgelegte Regeln oder Berechnungsvorschriften.

ML-Anwendungen oder »lernende Maschinen« sind nicht nur auf physische Geräte und Roboter beschränkt, sondern können auch rein digitale Anwendungen in IT-Systemen sein, wie verschiedene Arten von »Robos« und Bots, zum Beispiel Chatbots, Social Bots, Gamebots oder Robo-Player, Robo-Advisors oder Robo-Journalisten. ML-Techniken und KI-Anwendungen sind dabei, sämtliche Branchen und Lebensbereiche nachhaltig

zu beeinflussen. Es ist ein enormer globaler Wettbewerb rund um dieses Zukunftsfeld entfacht, der insbesondere zwischen den USA und China ausgetragen wird.

Die oftmals erstaunlich scheinenden Leistungen ML- und KI-basierter Systeme implizieren jedoch nicht, dass die Maschine irgendein Verständnis oder gar Bewusstsein davon hat, welche Daten sie verarbeitet, warum und in welchem Kontext sie das tut und welche Bedeutung die Daten haben. Auch eine menschenähnliche »Künstliche Universalintelligenz« oder gar eine »Künstliche Superintelligenz«, wie sie häufig in den Medien dargestellt und von einigen Forschern und Industrievertretern propagiert wird, spielt absehbar realistischweise keine Rolle. Die diskutierten Szenarien machen allerdings auf etwaige generelle Risiken aufmerksam.¹

Die existierenden ML-Anwendungen sind mit großem Aufwand konstruiert und lediglich für enge Aufgaben trainiert und einsatzbereit. Die derzeitige Forschung beschäftigt sich vorrangig damit, den Trainingsaufwand zu reduzieren, Robustheit, Sicherheit und Transparenz der Modelle zu verbessern, sie leichter an neue Aufgaben anzupassen und die Kompetenzen von Mensch und Maschinen zweckmäßig zu kombinieren.

ML-basierte Maschinen werden zukünftig in vielen Bereichen zusehends Entscheidungen selbstständig treffen können. Das ruft aus unterschiedlichen Perspektiven neue rechtliche Fragestellungen auf den Plan, beispielsweise zur Haftung bei Schäden und Mängeln, zur Verantwortung von Inhalten und Urheberrechtsfragen, zur Transparenz von Entscheidungen, zum Daten- und Verbraucherschutz oder zur Frage, inwieweit den Entscheidungen von solchen Maschinen Folge zu leisten ist. Die zentrale ethische Herausforderung ist es, die Maschinen so zu gestalten, dass sie mit unseren Gesellschafts-, Rechts- und Wertevorstellungen kompatibel sind. Diese gesellschaftliche Debatte muss jetzt beginnen.²

¹ De Spiegeleire/Maas/Sweijjs 2017

² Bitkom 2017

1.2 Ein kurzer historischer Überblick

Maschinelles Lernen kann auf eine recht lange Geschichte zurückblicken und ist aus Methoden der Statistik und KI hervorgegangen. Angeregt durch das Verständnis verteilter neuronaler Prozesse im Gehirn entstanden bereits in den späten 1940er Jahren erste Konzepte von Künstlichen Neuronalen Netzen (KNN) und fanden zehn Jahre später erste Implementierungen. Ende der 1960er Jahre haben zwei bekannte KI-Wissenschaftler, Minsky und Papert, gezeigt, dass damals ein einziges Neuron schon die elementare Entweder-oder-Logik nicht lernen konnte und größere Neuronale Netze

mit wenigen lokalen Vernetzungen in ihrer Ausdrucksfähigkeit beschränkt waren. Dies führte in den 1970er Jahren zur Stagnation der KI-Forschung, insbesondere an KNN, und leitete den sogenannten ersten »KI-Winter« ein.

In den 1980er Jahren konzentrierte sich die Forschung auf symbolische Expertensysteme. Ihre Wissensbasis bestand aus manuell eingegebenen logischen Regeln, die sich auf manuell selektierte Merkmale oder ebenfalls manuell konstruierte Objekthierarchien bezogen. Solche Wissensrepräsentationen bezeichnet man als »symbolisches Wissen«. Es stellte sich aber heraus, dass ein konsistenter Ausbau größerer Wissensbasen

Tabelle 1: Überblick zu ausgewählten Meilensteinen im Einsatz von Maschinellem Lernen

heute	ML-basierte Systeme sind inzwischen in der Lage, <ul style="list-style-type: none"> radiologische Bilder so gut wie Mediziner zu analysieren automatisch unklare Bilder zu vervollständigen selbst KI-Software zu schreiben und zu trainieren Börsengeschäfte anhand eigener Prognosen selbstständig durchzuführen in komplexen Spielen wie Go und Poker gegen Menschen zu gewinnen sich selbst Wissen, Spiele und Strategien beizubringen
2017	KI (Alpha Go) gewinnt im Go-Spiel gegen den »besten Spieler der Weltrangliste« Ke Jie
2011	KI gewinnt im Quiz-Spiel (IBM Watson)
2010er	Bedeutende Erfolge mit Deep Learning (v. a. in der Sprachverarbeitung, Objekterkennung, Mustererkennung, Bioinformatik)
2000er	Popularitätsgewinn des ML: Revival der Neuronalen Netze (Big Data und schnelle Computer); Verbreitung der Kernel-Methoden des ML
1996	KI gewinnt im Schach gegen den Weltmeister Kasparow (IBM Deep Blue)
1990er	Durchbruch: Stützvektormaschinen (SVM)
1985-1995	Stagnation der Forschung und Entwicklung: Aufgabe der Expertensysteme (zu hohe Komplexität und langsame Computer)
1980er	Praktische Anwendung der »Back Propagation«-Methode für ML und KNN; Forschung an Expertensystemen
1980er	Boom der humanoiden Robotik (Japan)
1974-1980	Stagnation der FuE: Scheitern Neuronaler Netze (zu langsame Computer)
1960er	Entwicklung: Bayessche Netze, probabilistisches ML und semantische Netze
1950er	Pionierarbeiten im Maschinellen Lernen (ML); Begriffsprägung der Künstlichen Intelligenz (KI)
1940er	Theorie der »Künstlichen Neuronalen Netze« (KNN)

immer schwerer wurde. Man erkannte, dass praktisch niemals alle denkbaren Vorbedingungen für eine Aktion explizit angegeben werden können. Zudem traten Probleme im Umgang mit neuen Informationen auf, die bereits eingegebenem widersprachen. Das führte Ende der 1980er zum zweiten »KI-Winter«.

Mitte der 1980er Jahre wurden Neuronale Netze zwar durch die Back-Propagation-Methode wieder interessant. Für praktische Anwendungen stellten sich ab 1995 aber Lernmethoden wie Stützvektormaschinen als handhabbarer heraus.

Erst um die Jahrtausendwende ermöglichten Fortschritte in den Computertechnologien und das Aufkommen von »Big Data« das Lernen von sehr komplexen, sogenannten »tiefen« Künstlichen Neuronalen Netzen. Damit begann der Erfolg der heutigen KI.

1.3 Lernaufgaben, Lernstile, Modelle und Algorithmen

Bei maschinellen Lernverfahren unterscheidet man Lernstile, die für jeweils andere Zwecke geeignet sind. Je nachdem, welche Zusatzinformation zur Verfügung steht, können andere Aufgaben gelernt werden. Beim überwachten Lernen müssen die richtigen Antworten zu den Beispielen

als sogenannte Labels mitgeliefert werden. Die Angabe von Labels bedeutet meist mehr Arbeit für die Datenvorverarbeitung, ist aber notwendig, wenn Objekte klassifiziert und Werte geschätzt oder vorhergesagt werden sollen. Beim unüberwachten Lernen hingegen reichen die rohen Beispieldaten aus, um grundlegende Muster in den Daten zu entdecken. Beim bestärkenden Lernen nutzen Maschinen Feedback aus ihrer Interaktion mit der Umwelt, um ihre zukünftigen Aktionen zu verbessern und Fehler zu verringern. Diese Art des Lernens kommt häufig in der Robotik zum Einsatz, beispielsweise zum Erlernen der besten Greifbewegungen für Objekte.


Es gibt inzwischen eine Vielzahl von Modelltypen und Lernverfahren bzw. konkreten Lernalgorithmen, die jeweils für unterschiedliche Aufgaben besonders gut geeignet sind. Die meist verbreiteten sind in Tabelle 2 zusammengestellt.

Kaggle, eine Plattform für ML-Wettbewerbe, hat 2017 in einer Umfrage nach den verwendeten Methoden gefragt. Das Ergebnis auf Basis von 7 301 Antworten zeigt Abbildung 1. Ensemble-Methoden und »Gradient boosted machines« kombinieren mehrere Modelle, meist Entscheidungsbäume, für Klassifikations- und Regressionsaufgaben. CNN und RNN gehören zu den tiefen Neuronalen Netzen.

Tabelle 2: Gängige Lernverfahren und ihre Modelle

Lernstil	Lernaufgabe	Lernverfahren	Modell
Überwacht	Regression	Lineare Regression	Regressionsgerade
		Klassifikations- und Regressionsbaumverfahren (CART)	Regressionsbaum
	Klassifikation	Logistische Regression	Trennlinie
		Iterative Dichotomizer (ID3)	Entscheidungsbaum
		Stützvektormaschine (SVM)	Hyperebene
		Bayessche Inferenz	Bayessche Modelle
Unüberwacht	Clustering	K-Means	Clustermittelpunkte
	Dimensionsreduktion	Kernel Principal Component Analysis (PCA)	Zusammengesetzte Merkmale
Bestärkend	Sequentielles Entscheiden	Q-Lernen	Strategien
Verschiedene	Verschiedene	Rückwärtspropagierung	Künstliche Neuronale Netze

Abbildung 1: Verwendete Methoden der von Kaggle befragten Data Scientists und ML-Fachleute³



1.4 Tiefe Neuronale Netze

Ab 2006 verzeichnete das Deep Learning oder das Lernen mit tiefen Künstlichen Neuronalen Netzen enorme Fortschritte, insbesondere in der Analyse von Bild- und Video-, Sprach- und Textdaten. Inzwischen können Maschinen mit tiefen KNN in einigen Fällen Gesichter und Objekte mit einer geringeren Fehlerquote identifizieren als Menschen und sogar Fachleute⁴. Außerdem können solche Maschinen neuartige Lernaufgaben mit komplexen Ergebnissen lösen wie Texte übersetzen, Fragen und E-Mails beantworten, Nachrichten zu Berichten verdichten, Musik und Texte komponieren oder Bilder produzieren.

Die tiefen KNN bestehen aus vielen in Software realisierten Schichten von »Knoten«, die als künstliche Neuronen bezeichnet werden (siehe Abb. 2). Beim Lernen werden die Gewichte, das sind Zahlenwerte an den Verbindungen zwischen den Knoten, solange verändert, bis die Ausgaben gut genug sind. In ihren inneren Schichten gewinnen die Netze aus den Rohdaten selbstständig kompakte Darstellungen, wodurch viele Vorverarbeitungsprogramme überflüssig werden und die eigentliche Aufgabe leichter lernbar wird. Tiefe KNN bilden ausdrucksstarke Modelle, die sich außerdem effizient in parallelen Rechnersystemen trainieren lassen. Das funktioniert

oft nur sinnvoll mit sehr großen Datenmengen. Da es sich dem Menschen nicht ohne weiteres erschließt, was die Gewichtungen bei einem KNN bedeuten und wie genau die Ausgaben zustande kommen, spricht man hier von »subsymbolischen« Modellen, im Gegensatz zu symbolischen Modellen wie den Entscheidungsbäumen (siehe Abb. 3) oder den Wissensbasen früherer Expertensysteme.

Es gibt eine Vielzahl von Netzarchitekturen, die sich für jeweils unterschiedliche Datentypen und Aufgabenstellungen als wirkungsvoll erwiesen haben. Da die Netze im Ganzen von den Rohdaten bis zur Ausgabe trainiert werden können, spricht man auch von Ende-zu-Ende-Lernen. Eine sehr erfolgreiche Anwendung von tiefen KNN sind die »Deep Q-Networks« im bestärkenden Ende-zu-Ende-Lernen⁵ für Spiele und Roboter.

1.5 Herausforderungen des Maschinellen Lernens

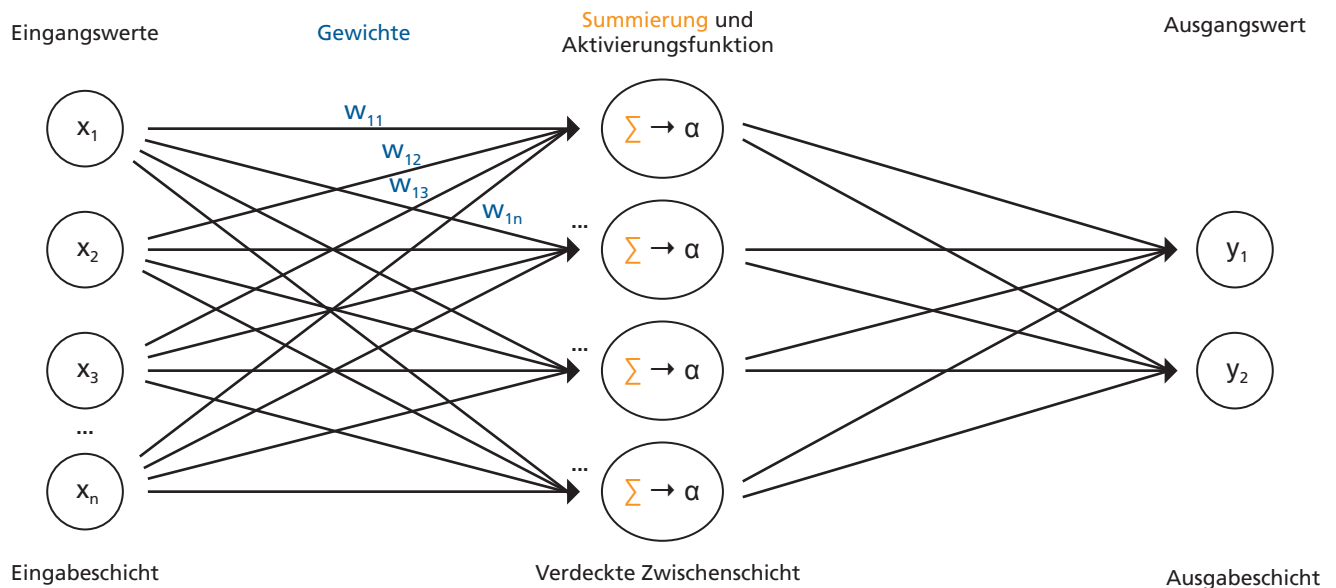
Beim Maschinellen Lernen als datengestützter Technologie gibt es ganz andere Herausforderungen als bei der klassischen Programmierung. Generell gilt: je mehr Trainingsdaten ein Lernalgorithmus erhält, desto eher kann er sein Modell verbessern und die Fehlerquote verringern. Dabei besteht die Kunst darin, das Modell allgemein genug zu halten, damit es auch auf neuen Daten, die nicht in der Trainingsphase

³ Kaggle 2017

⁴ He et al. 2015

⁵ Mnih et al. 2015

Abbildung 2: Schematische Darstellung eines KNN, hier in Form eines Feed-forward Network – eigene Darstellung




vorkamen, gut funktioniert. Außerdem sollen die Modelle robust sein, also auf ähnliche Eingaben auch ähnlich reagieren.

Die Qualität eines Modells hängt auch von der Qualität der Trainingsdaten ab. Werden dem Algorithmus zu viele falsche Beispiele gezeigt, kann er nicht die korrekten Antworten lernen. Wenn die Beispiele nicht repräsentativ sind, sind die Ausgaben bei neuartigen Eingaben auch mit größerer Unsicherheit behaftet. Manche Modelle können aber zusammen mit ihrer Ausgabe auch eine Einschätzung abliefern, wie fundiert die Ausgabe ist.

Eine wünschenswerte und wichtige Eigenschaft ist die Nachvollziehbarkeit der Modelle im Allgemeinen und ihrer Ergebnisse im Einzelfall. Entscheidungsbäume lassen sich besonders gut interpretieren, tiefe Neuronale Netze hingegen schlecht.

Die gute Skalierbarkeit mit steigenden Datenmengen einerseits und die schlechte Nachvollziehbarkeit andererseits sind Gründe, weshalb die im Projekt konsultierten Fachleute das tiefe Lernen für notwendig, aber nicht ausreichend

Abbildung 3: Schematische Darstellung eines Entscheidungsbaums⁶



für erfolgreiche ML-Anwendungen halten. Die Wahl der Methode sollte sich immer nach den Anforderungen der Aufgabe richten. In Deutschland gibt es auch zukünftig viele Einsatzbereiche für klassische Lernverfahren, die weniger Daten benötigen – wie die hier stark vertretenen Stützvektormaschinen und Kernmethoden. Noch größeres Potenzial sehen die Fachleute aber in der Verbindung von maschinellen Lernverfahren mit anderen Wissensformen.

6 Snider 2017

2 AKTEURE UND KOMPETENZLANDSCHAFT

Im Zuge der fortschreitenden Digitalisierung in nahezu allen Lebensbereichen nehmen Maschinelles Lernen und Künstliche Intelligenz eine bedeutende strategische Rolle im wirtschaftlichen, zivilen und militärischen Bereich ein.^{7,8} Somit rücken sie auch immer stärker in den Fokus von Politik, Wissenschaft und Wirtschaft, um im globalen Wettbewerb um Forschungs- und Entwicklungserfolge, Talente, Daten sowie kommerzielle Anwendungen mithalten zu können. Auch in den USA äußern sich inzwischen besorgte Stimmen, in KI- und ML-basierter Forschung und Technologie insbesondere von China, aber auch von Russland überholt zu werden.⁹

Ziel dieser Analyse ist es, einen Überblick über die Forschungsaktivitäten im Bereich ML zu geben mit einem besonderen Blickpunkt auf den Standort Deutschland. Als Methode hierfür dienen statistische Analysen über wissenschaftliche Publikationen, Patentanmeldungen sowie öffentlich geförderte Forschungsprojekte. All diese Indikatoren bestätigen ein starkes Wachstum der ML-Themen in den letzten zehn Jahren. Ebenfalls wurden wissenschaftliche und wirtschaftliche Aktivitäten von Akteuren in vier bedeutenden Anwendungsbereichen betrachtet, die ML auf bestimmte Datentypen anwenden: Bild- und Videoanalyse, Text- und Sprachverarbeitung, Verarbeitung von Audiodaten sowie heterogene Datenquellen.

Bild- und Videoanalyse

Bei der Bild- und Videoanalyse handelt es sich um die Verarbeitung visueller Daten (z. B. von optischen Sensoren, Kamerasystemen oder Bildern). Dies ermöglicht es einer Maschine, Objekte, Szenen und Aktivitäten in der Umgebung wahrzunehmen und zu identifizieren. Ein Computer-Vision-System erfasst, verarbeitet und analysiert Bilder, um numerische oder symbolische Informationen zu erzeugen. Die traditionelle Herangehensweise, bei der in möglichst kleinen Teilschritten, wie dem Erkennen von Linien und Texturen, Bilder berechnet und analysiert

werden, um anschließend die Merkmale mit bekannten Objekten auf wahrscheinliche Übereinstimmungen zu vergleichen¹⁰, wurde in den letzten Jahren durch das tiefe Lernen in KNN überholt. Deep Learning ermöglicht die Verarbeitung visueller Daten mit einer höheren Genauigkeit und Zuverlässigkeit in einem einzigen Schritt (end-to-end). Damit konnten bei Bildklassifikation, Objekterkennung und Bildsegmentierung im Maschinellen Sehen erhebliche Fortschritte erzielt werden.

Text- und Sprachverarbeitung

Text- und Sprachverarbeitung (Natural Language Processing, NLP) umfasst Techniken, die Computersysteme befähigen, natürliche Sprache in Wort und Schrift zu interpretieren und zu erzeugen. Die Algorithmen verarbeiten die menschliche Spracheingabe und wandeln sie in maschinenverständliche Darstellungen um.¹¹ Dazu gehören unter anderem: Erkennung gesprochener Sprache (speech recognition, automatische Transkription menschlicher Sprache); natural language generation, automatisiertes Schreiben von Texten in stark formalisierten Bereichen wie Sport- oder Finanznachrichten; Sentimentanalyse, die Analyse von Tonalität und Stimmung in Texten; maschinelle Übersetzung sowie das Führen von Dialogen und Unterhaltungen. Die semantische Interpretation ist dabei eine der großen Herausforderungen.

Audiodatenverarbeitung aus heterogenen Quellen

Viele Problemstellungen in datenintensiven Branchen wie Automobilindustrie, Fertigungsindustrie, Energiesektor oder Medizin erfordern die gleichzeitige Berücksichtigung großer Mengen von Signalen aus verschiedenen, heterogenen Quellen in Echtzeit. Im Rahmen der KI-gestützten Sensordatenfusion werden statistische Interdependenzen zwischen unterschiedlichen Datenquellen unter Verwendung von Bayes-Netzwerken

7 The Hague Centre for Strategic Studies 2017

8 Button 2017

9 Simonite 2017

10 Gentsch 2018

11 Rao und Verweij 2017

und probabilistischen grafischen Modellen genutzt. Vor allem Deep Learning wird verwendet, um Datenströme verschiedener Sensortypen (Beschleunigungsmesser, Gyroskop, Magnetometer, Barometer, Satellitenempfänger, usw.) zusammenzuführen.¹²


2.1 Publikationen

Ein in der Forschung etablierter Indikator für die Betrachtung wissenschaftlicher Aktivitäten sind wissenschaftliche Publikationen (Artikel in Fachzeitschriften bzw. Fachjournals und Konferenzbeiträge), die mit Hilfe von bibliometrischen Statistiken in Publikationsdatenbanken erfasst und recherchiert werden können. Die Elsevier-Scopus-Datenbank bildet als etablierte Publikationsdatenbank die Datengrundlage für die bibliometrischen Auswertungen der vorliegenden Untersuchung.¹³ Die Definition und Abgrenzung der relevanten Suchbegriffe für die Datenbankabfrage wurde in Zusammenarbeit mit ML-Fachleuten erstellt und erfolgte anhand von ausgewählten großen Anwendungsfeldern sowie auf der technologischen Systemebene anhand von ML-Methoden, Lernstilen und -aufgaben, Modellen und Lernverfahren.¹⁴

Die Anzahl der ML-Publikationen in wissenschaftlichen Fachzeitschriften ist im Zeitraum von 2006 bis 2016 von 9 636 auf 21 724 angestiegen. Auch ist die Anzahl der Konferenzbeiträge zu ML von 7 811 in 2006 auf 17 686 in 2016 gestiegen. Das Publikationsaufkommen in den Computerwissenschaften insgesamt hat sich im gleichen Zeitraum von 190 583 auf 319 523 zitierbare Publikationen erhöht.¹⁵ Die ML-Publikationen weisen damit ein relativ stärkeres Wachstum auf als der allgemeine Publikationstrend und lassen auf eine intensivere Forschungstätigkeit schließen.

Geographisch betrachtet, entfallen im Durchschnitt mehr als 60 % der ML-Publikationen auf die USA, EU und China. Diese Regionen publizieren in absoluten Zahlen am meisten. Innerhalb der EU ist Großbritannien, gefolgt von Deutschland, der publikationsstärkste Akteur. China weist innerhalb des Betrachtungszeitraums mit einer jährlichen Zunahme von durchschnittlich 15 % eine besonders hohe Wachstumsrate auf: so stieg der Anteil an den weltweiten ML-Publikationen von 13 % in 2006 auf 21 % in 2016. Wird jedoch nur die reine Anzahl der Veröffentlichungen in einschlägigen Konferenzbeiträgen ohne Berücksichtigung ML-bezogener

Abbildung 4: Entwicklung der Publikationen im Bereich ML für Deutschland (DE), Frankreich (FR), Großbritannien (UK), USA (US) und China (CN) sowie die restlichen EU-Staaten und übrige Länder



¹² Groopman und Kaul 2017

¹³ Erfasst sind über 67 Mio. Aufsätze in wissenschaftlichen Fachzeitschriften und rund 8 Mio. Konferenzbeiträge. Darüber hinaus gibt es noch weitere Datenbanken (z. B. Web of Science, Google Scholar, arXiv.org), die sich in Abdeckung und Qualität von der gewählten Datenbank unterscheiden. Es wurde keine Vorauswahl der Fachzeitschriften oder Konferenzbeiträge vorgenommen.

¹⁴ Neben dem Suchbegriff »Machine Learning« wurden in einem iterativen Prozess insgesamt 15 Suchbegriffe und 85 Schreibvariationen definiert. Die Suche wurde auf Publikationen in englischer Sprache im Zeitraum zwischen 2006-2016 sowie relevante Disziplinen (Physik und Ingenieurwissenschaften, Lebenswissenschaften, Wirtschafts- und Verhaltenswissenschaften) eingegrenzt. Da das Analyseziel die Identifikation von relevanten Akteuren war, die in der Forschung und Entwicklung von ML-Methoden und Technologien tätig sind, sollten mit der Disziplinenfokussierung beispielsweise Beiträge zur philosophischen oder ethischen Auseinandersetzung mit ML gefiltert werden.

¹⁵ Vgl. <http://www.scimagojr.com/worldreport.php> (zuletzt geprüft am 20.02.2018)

Tabelle 3: Top-10 der publikationsstärksten Akteure weltweit

Rang	Forschungseinrichtung	Land	Fachzeitschriften	Konferenzbeiträge	Summe
1	Tsinghua University	China	672	910	1582
2	Carnegie Mellon University	USA	445	917	1362
3	Zhejiang University	China	816	532	1349
4	Harbin Institute of Technology	China	646	613	1260
5	Shanghai Jiao Tong University	China	704	509	1213
6	Chinese Academy of Sciences	China	489	536	1025
7	Nanyang Technological University	Singapur	526	445	971
8	Huazhong University of Science and Technology	China	440	521	961
9	National University of Singapore	Singapur	476	439	915
10	Beihang University	China	372	518	889
...
31	Max-Planck-Gesellschaft	Deutschland	462	207	669
32	Helmholtz-Gemeinschaft	Deutschland	374	292	666
70	Technische Universität München	Deutschland	228	274	502
115	Fraunhofer-Gesellschaft	Deutschland	127	256	383
193	Rheinisch-Westfälische Technische Hochschule Aachen	Deutschland	114	169	283

Such- und Schlüsselbegriffe betrachtet, so kann die Stellung Chinas gegenüber den USA deutlich geringer ausfallen¹⁶.

Die zehn publikationsstärksten Organisationen stammen aus der Wissenschaft, wobei acht von zehn Organisationen aus Asien stammen.

Die Anzahl von Publikationen zu Deep Learning in wissenschaftlichen Zeitschriften und Konferenzbeiträgen wurde ebenfalls durch unterschiedliche Suchbegriffe erfasst. Seit 2013 kann bei den Fachkonferenzen ein starkes Wachstum konstatiert werden. Hier erreichte der Anteil von Deep Learning 2016 bereits 6,8 %. Im gleichen Jahr liegt der Anteil der DL-bezogenen Konferenzbeiträge in den USA mit 10,4 %


vergleichsweise hoch. In Großbritannien liegt er bei 8,7 %, in China bei 8,3 % und in Deutschland bei 5,3 %. Der Trend scheint in wissenschaftlichen Zeitschriften um zwei Jahre zeitversetzt einzutreten. Es ist davon auszugehen, dass die Dynamik in diesem Bereich weiter anhalten wird, denn tiefes Lernen steht im Mittelpunkt vieler Anwendungsszenarien.

In Deutschland ist die Anzahl der ML-Publikationen in Fachzeitschriften von 427 in 2006 auf 627 in 2016 angewachsen. Die Konferenzbeiträge sind im gleichen Zeitraum von 266 auf 617 angewachsen. Zum Vergleich sind die zitierbaren Publikationen aus Deutschland über alle wissenschaftlichen Disziplinen von 115 542 auf 149 645 angestiegen und in den Computerwissenschaften von 11 088 auf 18 691.¹⁷

¹⁶ EFI 2018

¹⁷ Vgl. <http://www.scimagojr.com/worldreport.php> (zuletzt geprüft am 20.02.2018)

Abbildung 5: Anteil der Deep-Learning-Publikationen an gesamten ML-Publikationen, 2006-2016



Deutsche Forscherinnen und Forscher leisteten insbesondere Pionierarbeit bei der Entwicklung von Support-Vektor-Maschinen. Weiterhin werden hier auch klassische ML-Technologien erforscht, verbessert und weiterentwickelt.

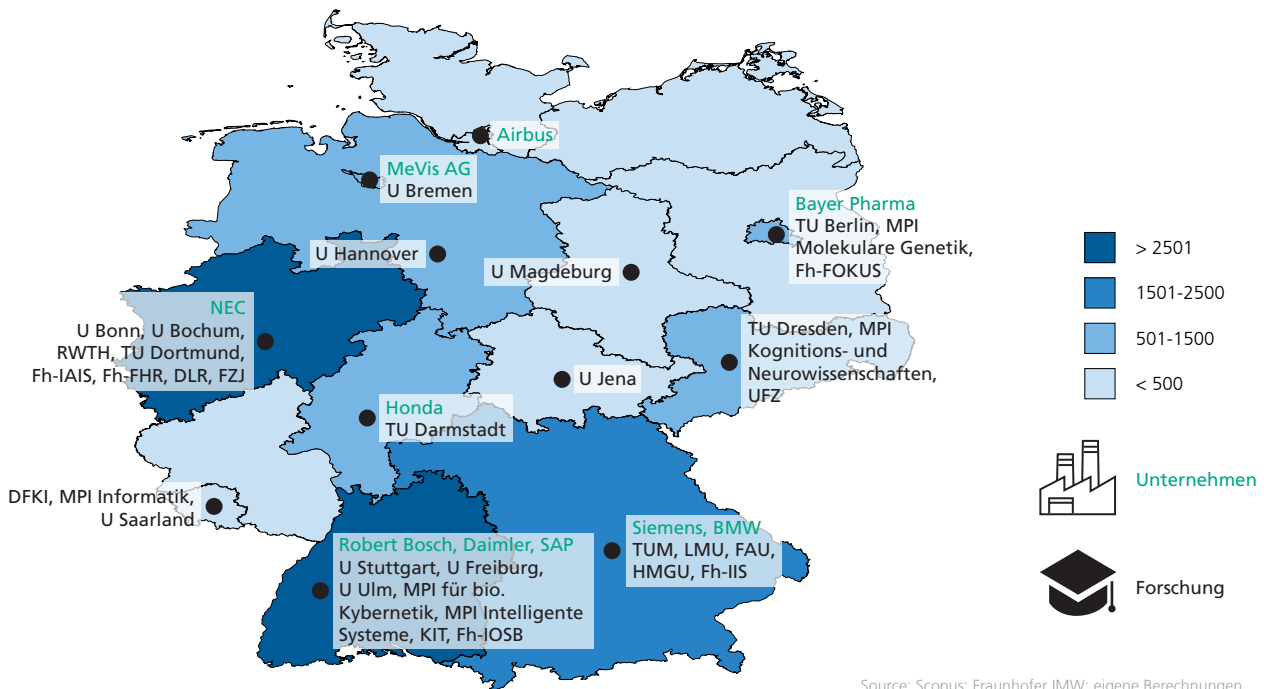
In absoluten Zahlen sind die Bundesländer Baden-Württemberg, Nordrhein-Westfalen und Bayern die publikationsstärksten im Bereich der ML-Technologien. Es folgen Niedersachsen, Berlin, Hessen und Sachsen. Die publikationschwächeren Bundesländer sind Rheinland-Pfalz, Saarland, Thüringen, Sachsen-Anhalt, Hamburg, Bremen und Schleswig-Holstein, Brandenburg und Mecklenburg-Vorpommern.

Deutschland verfügt über eine hohe Dichte an Forschungseinrichtungen. Das ML-Publikationsaufkommen in Deutschland ist stark konzentriert, so dass die 20 publikationsstärksten Einrichtungen über 40 % der ML-Publikationen hervorbringen. Hierzu zählen die Max-Planck-Gesellschaft (MPG), insbesondere das Max-Planck-Institut für Informatik, das Max-Planck-Institut für biologische Kybernetik und das Max-Planck-Institut für Intelligente Systeme, und die Helmholtz-Gemeinschaft (HGF), insbesondere das Deutsche Zentrum für Luft- und Raumfahrt (DLR) sowie das Karlsruher Institut für Technologie

(KIT). Mit einer starken Anwendungsorientierung befinden sich die Fraunhofer-Gesellschaft (FhG) und das Deutsche Forschungszentrum für Künstliche Intelligenz (DFKI) unter den führenden Wissenschaftseinrichtungen. Das DFKI publiziert stark in den Bereichen »Computerlinguistik«, »Mensch-Maschineinteraktion« und »Semantische Techniken«, hinter denen sich neben ML auch andere Techniken verbergen können. Unter den publikationsstärksten Hochschulen befinden sich insgesamt sechs Technische Universitäten: RWTH Aachen, TU Berlin, TU Darmstadt, TU Dortmund, TU Dresden und TU München. Bei der Einordnung und Bewertung der Einrichtungen müssen sowohl Größe als auch Zielrichtung der Organisationen berücksichtigt werden.

Bei den Unternehmen entfällt die Hälfte der zehn publikationsstärksten Akteure auf Softwarekonzerne aus den USA. Im Deutschen Raum verzeichnen die Siemens AG, Honda Motor Europe (North) GmbH (deutsche Niederlassung des japanischen Automobilkonzerns), SAP SE, Robert Bosch GmbH und Daimler AG die meisten Publikationen. Erwartbar war, dass Unternehmen in ihren ML-Publikationen stärkere Bezüge zu den definierten Anwendungsbereichen herstellen als Hochschulen oder Forschungseinrichtungen.

Abbildung 6: Kompetenzlandkarte auf Basis wissenschaftlicher Publikationen, 2006-2016



Abkürzungen: FAU= Friedrich Alexander Universität Erlangen Nürnberg; Fh = Fraunhofer-Institut; FZJ = Forschungszentrum Jülich; HMGU = Helmholtz Zentrum München; LMU = Ludwig-Maximilians-Universität München; MPI= Max-Planck-Institut; TUM = TU München; UFZ = Helmholtz-Zentrum für Umweltforschung

Tabelle 4: Anzahl der ML-Publikationen in Unternehmen

Rang	Organisation	Standort	Fachzeitschriften	Konferenzbeiträge	Summe
1	IBM Inc.	USA	197	594	790
2	Microsoft Inc.	USA	156	529	685
3	Google Inc.	USA	74	221	296
4	Yahoo Inc.	USA	54	229	283
5	Microsoft Research Asia Inc.	China	68	164	232
6	Siemens USA Inc.	USA	131	68	199
7	Nippon Telegraph and Telephone Corporation	Japan	68	123	191
8	Philips B.V.	Niederlande	111	68	180
9	Hewlett-Packard Inc.	USA	39	106	145
10	Intel Corp.	USA	38	106	144
...
13	Siemens AG	Deutschland	47	49	96
22	Honda Motor Europe (North) GmbH	Deutschland	18	20	38
30	SAP SE	Deutschland	2	29	32
37	Robert Bosch GmbH	Deutschland	6	20	26
48	Daimler AG	Deutschland	4	14	18

Tabelle 5: Die publikationsstärksten Forschungseinrichtungen Deutschlands im Bereich ML

Forschungseinrichtung ¹⁹	Publikationen 2006-2016			
	Fachzeitschriften	Konferenzbeiträge	Summe	
Deutsches Forschungszentrum für Künstliche Intelligenz DFKI	24	83	107	
Fraunhofer-Gesellschaft	127	256	383	
Friedrich-Alexander-Universität Erlangen-Nürnberg (FAU)	116	85	201	
Gottfried Wilhelm Leibniz Universität	36	79	114	
Helmholtz-Gemeinschaft (HGF)	374	292	666	
Ludwig-Maximilians-Universität München (LMU)	172	84	256	
Max-Planck-Gesellschaft (MPG)	462	207	669	
Otto von Guericke Universität Magdeburg	100	122	222	
RWTH Aachen	114	169	283	
Technische Universität Berlin	100	125	225	
Technische Universität Darmstadt	66	141	207	
Technische Universität Dortmund	53	102	154	
Technische Universität Dresden	111	95	206	
Technische Universität München	228	274	502	
Universität Bonn	177	66	243	
Universität Bremen	65	71	136	
Albert-Ludwigs-Universität Freiburg	100	101	201	
Universität des Saarlandes	64	64	128	
Universität Stuttgart	52	102	154	
Universität Ulm	77	71	148	

18 Die jeweiligen Forschungsschwerpunkte wurden anhand der Stichwörter zu konkreten ML-Lernverfahren und Anwendungsbereichen ermittelt, mit denen die Publikationen verschlagwortet wurden. Generell ist bei den Stichwörtern zu den Publikationen aller betrachteten Akteure auffällig, dass hier sehr viele Begriffe zu den Themen Gesundheit, Medizin und Lebenswissenschaften zu finden sind, z. B.: Alzheimer, Biomarker, DNA, fMRI, EEG, Gehirn, Genetik, Krebs, Neurowissenschaften, Prothetik etc., die hier nicht explizit als Anwendung aufgelistet wurden.

19 Alphabetisch sortiert.

Häufig genannte Forschungsthemen der Publikationen im Zeitraum 2014-2016 ¹⁸		
	Lernverfahren und Aufgaben	Anwendungen
	Support Vector Machine (SVM), Vereinfachung von Repräsentationen (weitere: Ensemble Learning, Merkmalsextraktion, KNN/Deep Learning)	Mustererkennung; Bildverarbeitung; Text- und Wissensanalyse, semantische Technologien
	KNN/Deep Learning, SVM (weitere: Merkmalsextraktion, PCA, Bayessche Modelle, statistisches ML, Entscheidungsbäume)	Aktivitäts- und Bewegungsanalyse; Muster- und Objekterkennung; Bildverarbeitung/-analyse (Vision); Vorhersageanalysen; Text-, Audio-, Video- und Geräuschanalyse
	KNN/Deep Learning, SVM/Kernmethoden (weitere: Bayessche Netze, Feature Maps, inverse Probleme)	Signalverarbeitung, Industrie 4.0, Sensordatanalyse, Semantik, Stimmerkennung
	Neuronale Netze (weitere: Active Learning, Entscheidungsbäume)	Text- und Semantikanalysen, Linked Data, Sensordatanalysen
	KNN/Deep Learning, SVM, Merkmalsextraktion (weitere: Bayessche Netze, statistisches ML, Active Learning, Entscheidungsbäume)	Hyperspektraldatenanalyse, Spektroskopie; Fernerkundung (Remote Sensing); Bildverarbeitung
	SVM/Kernmethoden, statistisches ML (weitere: KNN, Ensemble Methoden, Markov-Modelle)	Visualisierungen; Bild-, Sprach-, und Textverarbeitung
	KNN, SVM (weitere: statistische ML-Methoden, Bayessche Methoden)	Gesichts-, Muster- und Objekterkennung; Gehirn-Computer-Schnittstellen (BCI); Vorhersagemodelle
	SVM (weitere: KNN, genetische/evolutionäre Algorithmen, Merkmalsextraktion)	Mustererkennung; (IT)-Forensik; Bildverarbeitung (Vision)
	KNN/Deep Learning; (weitere: Markov Modelle, Statistische ML-Methoden)	Sprach- und Textanalyse, semantische Analysen; Bildanalysen; Aktivitätsanalysen; Energiesysteme
	Entscheidungsbäume, Deep Learning (weitere: SVM/Kernmethoden, Markov Modelle)	Gehirn-Computer-Schnittstellen (BCI); Mustererkennung; Signalverarbeitung
	Neuronale Netze, Markov-Modelle (weitere: Active Learning, SVM)	Aktivitätserkennung, Knowledge Discovery, Textanalyse, Agentensysteme, ML-Games, akustische Sensoranalyse
	Transfer-Learning (weitere: Active Learning, KNN/Deep Learning, SVM)	Ereignisdetektion, Wort- und Geräuscherkennung, Bild-, Form- und Szenenerkennung, Modellierungen (Graphik, Verkehr)
	Active Learning, SVM	Text-, Inhalts- und Medienanalyse, Knowledge Discovery, Geräuschanalyse
	KNN/Deep Learning, Active Learning; (weitere: SVM, Entscheidungsbäume, bestärkendes Lernen)	Bildanalyse; Sprachanalyse; Stimmungsanalyse; Emotionserkennung; Aktivitätsvorhersage (activity prediction)
	SVM (weitere: KNN)	Aktivitätsvorhersage (activity prediction); Bewegungsanalyse
	Neuronale Netze, SVM	Agentensysteme, Affective Computing/Emotionsanalyse, Detektionssysteme und Vorhersagemodelle (industrielle Produktion, Fehler, Kopien, Schadstoffe, Erdbeben)
	SVM, KNN/Deep Learning (weitere: Active Learning, Random Forests)	Sentimentanalyse, Entscheidungsunterstützung, Aktivitätserkennung, autonome Systeme/Roboter
	SVM, Neuronale Netze	Daten-, Text- und Social-Media-Analysen, Energiemanagementsysteme
	Neuronale Netze, SVM	Vorhersagemodelle, Optimierung und Steuerung (Produktion), Textanalysen, Wissensintegration
	SVM/Kernmethoden, KNN/Deep Learning	Affective Computing/Emotionserkennung, Sprach- und Textanalyse, Signalverarbeitung

Es konnten nur für ein Drittel der ML-Publikationen auch ML-Anwendungsbereiche bestimmt werden. Dies kann zum einen methodische Gründe haben, so ist eine eindeutige Abgrenzung der Anwendungsbereiche schwierig. Zum anderen muss davon ausgegangen werden, dass viele Forscherinnen und Forscher zu ML publizieren, ohne konkrete Anwendungsbereiche zu adressieren. Unternehmen stellen stärkere Bezüge zu den definierten Anwendungsbereichen her als etwa Hochschulen oder Forschungseinrichtungen.

Die internationale ML-Forschung adressiert insbesondere das Anwendungsfeld »Bild- und Videoverarbeitung« (51 %). Daneben stellen die maschinelle Sprachverarbeitung (22 %) und die Signalverarbeitung (12 %) wichtige Anwendungsbereiche dar. In diesem Zusammenhang sei daran erinnert, dass bei der Sprach- und Bildverarbeitung bislang die größten Erfolge mit Deep Learning erzielt wurden. Besonders auffällig sind die unterschiedlichen Forschungsschwerpunkte bei wissenschaftlichen Fachzeitschriften im Vergleich zu Konferenzbeiträgen. Forscher aus den USA und Deutschland veröffentlichten vergleichsweise mehr Publikationen zu Sprach- und Signalverarbeitung in Konferenzbeiträgen als in Fachzeitschriften.


International nimmt das Publikationsaufkommen bei der Sprach- und Signalverarbeitung seit 2011 stark zu, während es

bei der Audioverarbeitung (2 %) deutlich geringer ausfällt und insgesamt eine niedrigere Dynamik aufweist. Die deutsche Forschung folgt diesem Trend, adressiert jedoch überdurchschnittlich stark die Bild- und Videoverarbeitung (52 %). Neben der Bild- und Videoverarbeitung fokussieren die USA und China vergleichsweise stärker die Sprachverarbeitung (23 %) als Deutschland.

2.2 Patente

Patente sind ein wertvoller Indikator, um die technologische Leistungsfähigkeit von Forschungseinrichtungen, Unternehmen, Regionen oder Ländern nachzuvollziehen und Technologietrends abzuleiten. Untersuchungen zeigen, dass sich die Patentierbarkeit von ML-Techniken in den verschiedenen Patentsystemen stark unterscheidet.²⁰ Die Espacenet-Patentdatenbank des Europäischen Patentamts bildet die Grundlage für die hier verwendete statistische Analyse von Patentfamilien.²¹ Insgesamt kann für die Entwicklung von Patentanmeldungen ein stetiges Wachstum konstatiert werden. So sind die weltweiten Patentanmeldungen für ML-Technologien von 487 Patentfamilien in 2006 auf 1258 Patentfamilien in 2015 angestiegen. Die Patentdynamik im Bereich ML folgt dem weltweiten Trend: so stiegen die Patentfamilien über alle Technologiefelder von 901 973 in 2006 auf 1,55 Mio. in 2015 kontinuierlich an.²²

Abbildung 7: Entwicklung der Patentfamilien zu ML-Technologie nach Ländern, 2006-2015



Quelle: EPO; Fraunhofer IMW; eigene Berechnungen

²⁰ Neuhäusler et al. 2015.

²¹ Patentfamilien setzen sich aus einer oder mehreren nationalen oder internationalen Patentanmeldungen zusammen und schützen die gleiche technologische Erfindung in unterschiedlichen Patentsystemen. Analog zum oben skizzierten Ansatz für die Publikationen wurden auch hier die Felder Titel und Zusammenfassung der Datenbankeinträge semantisch durchsucht. Die Suche beschränkte sich auf Patentfamilien im Zeitraum 2006-2015.

²² WIPO statistics database. Letzte Aktualisierung: Dezember 2017.

Die meisten Patentfamilien werden von Organisationen aus den USA, China und Südkorea angemeldet. Diese drei Länder vereinen auf sich insgesamt über 75 % der weltweiten Patentfamilienanmeldungen im Bereich ML. Die Patentstatistik wird von den Unternehmen Microsoft, IBM, Google, Amazon, Cisco, Qualcomm (USA) sowie Samsung, Korea Electronics Telecomm (Südkorea), Huawei und ZTE (China) angeführt. ML-Techniken sind eine bedeutende Grundlage für die Entwicklung von Maschinen mit sogenannten »cognitive computing«-Fähigkeiten. Aus diesem Grund investieren Firmen in ML-Techniken bzw. kaufen entsprechende Start-up-Unternehmen auf. Auffallend ist, dass in Südkorea und China die Hochschulen und Forschungseinrichtungen zu den aktivsten Patentanmeldern gehören, während in den USA und Deutschland fast ausschließlich Unternehmen in der ML-Patentstatistik vertreten sind. Die Unterscheidung zwischen akademischen und unternehmerischen Patenten erlaubt teilweise Rückschlüsse auf die Reife der patentierten Techniken.

Die Patentedynamik deutscher Akteure ist kaum vergleichbar mit den Hauptwettbewerbern USA, China oder Südkorea: die Zahl deutscher Patentfamilien ist von 21 im Jahr 2006 auf 36 im Jahr 2015 angestiegen. Die Ergebnisse müssen im Kontext der Wirtschaftsstruktur der untersuchten Länder interpretiert werden. So liegen die Stärken der deutschen Wirtschaft im

Automobil-, Maschinen- und Anlagenbau, sowie der chemischen und pharmazeutischen Industrie, so dass potenziell weniger deutsche Unternehmen ML-Technologien zum Patent anmelden als die Hauptwettbewerber aus den USA oder aus Ostasien.

In absoluten Zahlen sind die patentstärksten Regionen in Deutschland wie bei den Publikationen Bayern und Baden-Württemberg, gefolgt von Nordrhein-Westfalen und Hessen. Unter den 20 führenden ML-Patentanmeldern finden sich überwiegend Unternehmen.

ML-bezogene Patentfamilien konnten für 75 Unternehmen identifiziert werden, davon 56 Großunternehmen (> 249 Mitarbeitende), allen voran Siemens AG, gefolgt von Robert Bosch GmbH, Deutsche Telekom AG, Daimler AG, BMW AG und SAP SE, 15 kleine und Kleinstunternehmen (< 49 Mitarbeitende), aber lediglich 4 mittlere Unternehmen (49-249 Mitarbeitende). Insbesondere stechen die Branchen Gesundheit, Mobilität, industrielle Produktion sowie Informations- und Kommunikationstechnik hervor. An dieser Stelle sei erneut auf die eingeschränkte Patentierbarkeit von Software bzw. computerimplementierten Erfindungen hingewiesen. Des Weiteren werden keine Unternehmen erfasst, die ML-Technologien nutzen, aber nicht selbst entwickeln.


Tabelle 6: Führende Einrichtungen nach Patentierung in ML-Anwendungsbereichen, 2006-2015

Bild- und Videoverarbeitung	Audioverarbeitung	Sprachverarbeitung	Signalverarbeitung
1. Microsoft Corp. (USA) 2. Samsung Group (Südkorea) 3. Siemens AG (Deutschland) 4. Sony Corp. (Japan) 5. Chinese Academy of Sciences (China)	1. University of Korea (Südkorea) 2. Amazon Inc. (USA) 3. Samsung Group (Südkorea) 4. Inha-Industry Partnership Institute (Südkorea) 5. IBM Corp.(USA)	1. Microsoft Corp. (USA) 2. IBM Corp. (USA) 3. Korea Electronics Telecomm (Südkorea) 4. Yahoo Inc. (USA) 5. Google Inc. (USA)	1. Sensormatic Electronics (USA) 2. Microsoft Corp. (USA) 3. Robert Bosch GmbH (Deutschland) 4. Hyundai Motor Co. Ltd (Südkorea) 5. IBM Corp. (USA)

Tabelle 7: Führende Einrichtungen ML-Anwendungsbereiche in Deutschland, 2006-2015

Bild- und Videoverarbeitung	Audioverarbeitung	Sprachverarbeitung	Signalverarbeitung
1. Siemens AG 2. Robert Bosch GmbH 3. Sanofi-Aventis Deutschland GmbH 4. Beckhoff Automation GmbH 5. Daimler AG	1. Nero AG 2. Schäffler AG 3. Fraunhofer-Gesellschaft 4. TU Dresden 5. Siemens AG	1. Deutsche Telekom AG 2. Siemens AG 3. Audi AG 4. Becker Automotive Systems GmbH 5. EXB Asset Mgt. GmbH	1. Robert Bosch GmbH 2. Siemens AG 3. Balluff GmbH 4. Brainlab AG 5. Hartmann AG


Abbildung 8: Anzahl der deutschen Unternehmen mit Patentaktivitäten



Ähnlich wie bei der Publikationsanalyse zeigt sich, dass der ML-Anwendungsbereich »Bild- und Sprachverarbeitung« überproportional stark patentiert wird. Außerdem entfällt nahezu die Hälfte der ML-Anwendungen auf die Kategorie »heterogene Daten«, also auf die Kombination von zwei oder mehr Datentypen, die ebenfalls Sprach- und Bilddaten umfassen können.

Aus Deutschland werden insbesondere ML-Techniken für die Bild- und Videoverarbeitung (31 %), Signalverarbeitung (13 %) und Sprachverarbeitung (6 %) durch Patente geschützt. Führend sind eindeutig die USA mit 1 486 Patentfamilien. Der Fokus liegt hier ebenfalls auf der Bild- und Videoverarbeitung (20 %) und der Sprachverarbeitung (16 %). Die Daten für China zeigen, dass die Anbieter einen starken Schwerpunkt auf »Bild- und Videoverarbeitung« (19 %) legen, gefolgt von der »Audioverarbeitung« (7 %). Die Sprach- und Signalverarbeitung spielt für chinesische Hersteller eine untergeordnete Rolle. Für Südkorea kann eine ähnliche Entwicklung festgehalten werden: so werden dort vorwiegend Erfindungen zur Bild- und Videoverarbeitung (18 %) und Audioverarbeitung (18 %) zum Patent angemeldet. Aus Japan werden insbesondere ML-Techniken für die Bild- und Videoverarbeitung (31 %) und die Sprachverarbeitung (15 %) durch Patente geschützt. Entgegen dem Patentverhalten der asiatischen Länder ist in Deutschland und den USA auch die Signalverarbeitung von Bedeutung.

Abbildung 9: Entwicklung der Patentfamilien für ML-Anwendungsbereiche, 2006-2015



Quelle: EPO; Fraunhofer IMW; eigene Berechnungen

Tabelle 8: ML-Patentfamilien nach Anwendungsbereichen, 2006-2015

	Bild- und Video- verarbeitung	Audioverarbeitung	Sprachverarbeitung	Signalverarbeitung	Heterogene Daten
Welt	932	64	602	310	2141
	23 %	2 %	15 %	8 %	53 %
Deutschland	43	4	9	18	66
	31 %	3 %	6 %	13 %	47 %
USA	298	14	241	147	789
	20 %	1 %	16 %	10 %	53 %
China	140	56	8	20	530
	19 %	7 %	1 %	3 %	70 %
Südkorea	145	20	143	41	437
	18 %	3 %	18 %	5 %	56 %
Japan	75	2	35	12	116
	31 %	1 %	15 %	5 %	48 %

3 MÄRKTE UND BRANCHEN

Fortschritte in der Computertechnologie, der rasante Anstieg der verfügbaren Datenmengen und die wachsenden neuen Möglichkeiten, die sich durch ML eröffnen, haben inzwischen einen enormen globalen Wettbewerb um die Weiterentwicklung intelligenter Systeme und Anwendungen entfacht. Führende internationale Hochtechnologieunternehmen investieren deshalb zunehmend in die Forschung und Entwicklung von ML-Verfahren, die schnellere, präzisere und effizientere Ergebnisse bei der Analyse großer Mengen heterogener und komplexer Daten liefern und innovative Anwendungen insbesondere auf den Gebieten der Bild- und Objekterkennung, Verarbeitung natürlicher Sprache und der intelligenten Robotersteuerung ermöglichen.

3.1 Techniken in der Anwendung

ML-Unternehmen spezialisieren sich auf die Entwicklung von ML-Software und -Plattformen, bieten Cloud-basierte ML-as-a-service-Lösungen an und entwickeln ML-angereicherte Produkte und Dienste für fast alle Branchen.²³ In den kommenden Jahren entsteht verschiedenen Prognosen zufolge ein großer internationaler Markt für ML-basierte Produkte und Dienstleistungen, die insbesondere datenintensive Bereiche mit hohem Automatisierungspotenzial wie Transport, Gesundheitswesen, Energie und industrielle Fertigung transformieren werden.²⁴

Unter den ML-Techniken steht das Deep Learning im Mittelpunkt vieler Anwendungsszenarien. Die weltweiten Einnahmen aus Software für Deep Learning werden den Prognosen von Tractica²⁵ zufolge von 654,9 Mio US-Dollar (2016) auf 34,9 Mrd US-Dollar (bis 2025) ansteigen und im Jahr 2025 57 % des gesamten KI-Marktes ausmachen.

Der jährliche Gesamtumsatz für Deep-Learning-Software, -Dienstleistungen und -Hardware soll von 3,3 Mrd US-Dollar im Jahr 2016 auf 160 Mrd US-Dollar im Jahr 2025 bei einer jährlichen Wachstumsrate von 54 Prozent steigen.

Wie bei vielen Softwaretechniken fand die Einführung von ML-Produkten in den ersten Jahren überwiegend in Nordamerika statt, bevor sie im Rest der Welt zur Anwendung kamen. Die höchsten Wachstumsraten finden sich gemäß den Prognosen vor allem im ostasiatischen Raum.²⁶ Die globalen Vorreiter auf dem heutigen ML-Markt sind führende Technologieunternehmen aus den USA (vor allem Amazon, Facebook, Google, IBM, Intel, Microsoft, NVIDIA, Tesla) und China (vor allem Baidu, Alibaba, Tencent). Diese Akteure haben einen begünstigten Zugang zu massiven Mengen an Lerndaten und entsprechender Hardware, bauen Forschungsgruppen für Künstliche Intelligenz und Deep Learning auf und nutzen für das Training ML-Algorithmen auf eigenen ML-Plattformen.²⁷

Demgegenüber verfügen kleinere Anbieter und Start-ups über geringere Ressourcen. Als vertikale Akteure entwickeln sie auf Open-Source-Frameworks spezialisierte Produkte orientiert an bestimmten Problemstellungen oder einzelnen Branchen. Beispiele hierfür sind die Verwaltung von Kreditverträgen für die Finanzindustrie²⁸, Big Data Analytics für Beratungsunternehmen und Managed-Services-Anbieter²⁹, Sprachassistenten für das Autofahren³⁰ oder Deep Learning für industrielle Anwendungen.³¹

Das weltweite Gesamtvolumen an Investitionen in Deep-Learning-Start-ups belief sich einer aktuellen Studie von Cliperton zufolge im Jahr 2016 auf 594 Mio Euro. Nach London ist Berlin das zweitgrößte Zentrum für KI-Start-ups in Europa,

23 Nach Böttcher et al. 2017

24 Austin und Krensky 2017; Gartner 2017

25 Groopman und Kaul 2017

26 Groopman und Kaul 2017

27 Z. B. Microsoft Azure, IBM Watson, Amazon Web Services.

28 <https://leverton.de/> (zuletzt geprüft am 20.02.2018)

29 <http://www.panoratio.com> (zuletzt geprüft am 20.02.2018)

30 <https://www.hellochris.ai/> (zuletzt geprüft am 20.02.2018)

31 <https://www.twentybn.com/> (zuletzt geprüft am 20.02.2018)

über 50 Unternehmen haben in der deutschen Hauptstadt ihren Sitz. Die international begrenzte Verfügbarkeit von KI-Talenten und -Know-how spiegelt sich in der hohen Akquisitionsaktivität der Hochtechnologieunternehmen wider. Damit versuchen sie, Start-ups bereits in einem frühen Entwicklungsstadium zu erwerben, bevor sie erfolgreiche Geschäftsmodelle mit ihren Produkten auf dem Markt platzieren können.³²

Die deutsche ML-Unternehmenslandschaft ist heterogen und fragmentiert, aufgeteilt in Dienstleister, Software- und Tool-Anbieter wie SAP als große Akteur sowie Kleinunternehmen und Start-ups, die einzelne industriespezifische Nischen adressieren. Maschinelles Lernen findet sich darüber hinaus als Thema in den Unternehmensstrategien großer Technologieunternehmen, die ML- und KI-basierte Techniken in eigenen FuE-Abteilungen und Forschungsgruppen weiterentwickeln und in eigene Produkte oder Prozesse integrieren (u. a. Siemens, Daimler, Bosch, VW, Audi). Der deutsche Mittelstand ist unter den Anbietern und Entwicklern hingegen gering vertreten. Die konsultierten ML-Fachleute wiesen darauf hin, dass die Ursachen hierfür weniger in einer grundsätzlich fehlenden Bereitschaft liegen, sondern eher an vorhandenen Unsicherheiten, dem Bedarf an zielgerichteten fachlichen Kompetenzen und einem unzureichenden Zugang zu Daten, der für ML essenziell ist.

3.2 Anwendungsbranchen und Produkte

Maschinelles Lernen hat den Interviewaussagen zufolge das Potenzial, beinahe in allen Branchen erfolgreich kommerziell eingesetzt zu werden. In Deutschland wurden die ersten Produkte bereits Anfang der 1990er Jahre entwickelt, darunter auch tiefe Neuronale Netze für industrielle Anwendungen. Zentrale Anwendungsfelder sind heute vor allem die Bild- bzw. Videoanalyse sowie die Sprachverarbeitung. Als einen bedeutenden Trend nennen die Fachleute den Einsatz von Wissensgraphen, zum Beispiel in der Medizin. Neben Automobilindustrie, Maschinen- und Anlagenbau sowie Finanzdienstleistungen werden Gesundheitswesen, Telekommunikation, Landwirtschaft, Kundendienst, Konsumelektronik und intelligente Umgebungen (Smart Home) sowie Verteidigung, zivile Sicherheit und die öffentliche Verwaltung als zukunftsweisend betrachtet.

Das Gesundheitswesen stellt eine der zentralen Anwendungsbranchen für ML dar. Hier wird vor allem das Deep Learning zur Analyse von medizinischen Bildern (MRT, CT, Röntgen) und anderen komplexen, unstrukturierten Daten eingesetzt. Weitere Einsatzbeispiele sind die effiziente Verwaltung von Patientendaten und die derzeit meist noch prototypischen Systeme zur Entscheidungsunterstützung bei der klinischen Diagnostik sowie Anwendungen in der Radiologie, Pathologie und Dermatologie. Derzeit erlauben ML-Techniken schon, Brustkrebs, Herzerkrankungen, Osteoporose und erste Anzeichen von Hautkrebs zu identifizieren. Zukünftig werden Systeme zur frühzeitigen Erkennung und Prävention von Pandemien erwartet, ebenso wie kollaborative Service-roboter³³ zum Beispiel für die Pflegeunterstützung.³⁴ Umsetzungs Herausforderungen im medizinischen Bereich liegen insbesondere in der datenschutzrechtlichen Regulierung bei der Nutzung von Patientendaten, der Transparenz der Systeme sowie der Anwenderakzeptanz. Für das Jahr 2025 wird für Anwendungen von Deep Learning im Gesundheitswesen ein Umsatzvolumen von 3 Mrd US-Dollar prognostiziert.³⁵

Auch im Kontext von Industrie 4.0 und der Digitalisierung der Produktion bietet ML reichlich Potenzial in der Automatisierung von Produktionsprozessen und in der Industrierobotik, insbesondere im Bereich der Bild- und Videoverarbeitung und Handlungsplanung. Hinzu kommen neue Geschäftsmodelle durch die Analyse von Industriedaten und darauf basierende Dienstleistungen im Service-Bereich: Monitoring, Analysen und Prognosen, zum Beispiel für die präventive Wartung, die Prozess-, Logistik- und Energieoptimierung sowie das Qualitätsmanagement.

Bis 2030 wird eine Vervielfachung der Umsätze durch KI-gestützte Optimierung von Produktivität, Qualität und Personalisierung prognostiziert. Es wird erwartet, dass sich dies vor allem in den Bereichen Produktion und Transport niederschlägt. Durch Effizienzgewinne wie Automatisierung und Unterstützung von Arbeitskräften wird eine globale Produktivitätssteigerung von 55 % im Zeitraum von 2017 bis 2030 vorhergesagt.³⁶ Der jährliche Umsatz für Anwendungen des Deep Learning in der industriellen Fertigung wird im Jahr 2025 global 762 Mio US-Dollar erreichen.³⁷

³² Valorge et al. 2017

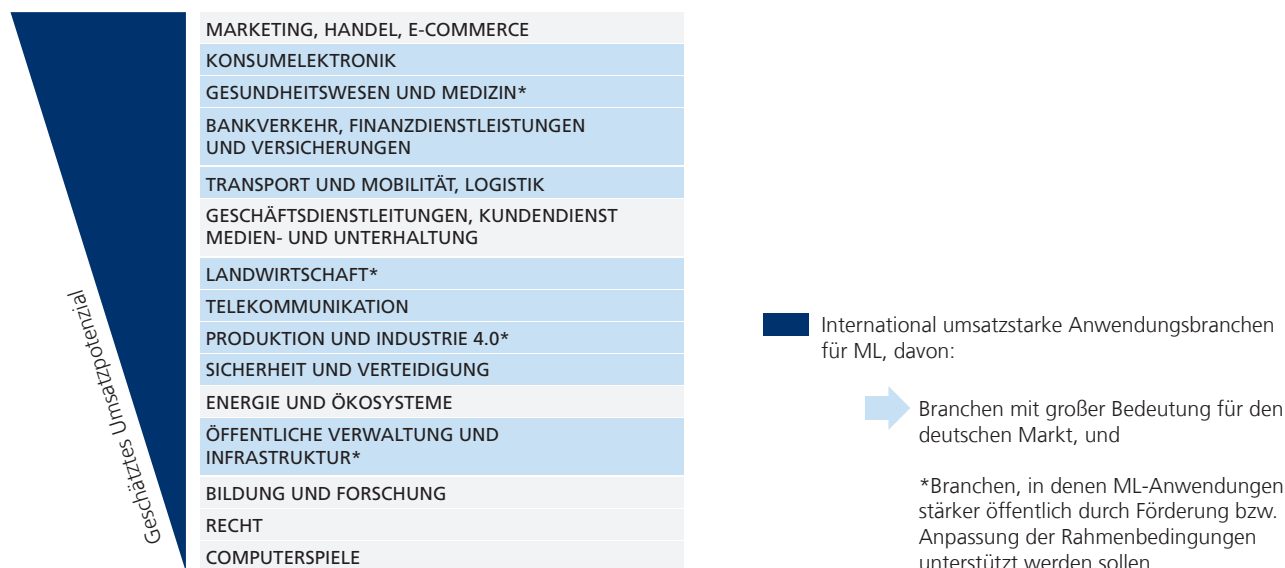
³³ Kollaborative Roboter, oder Koboter übernehmen zunehmend komplexere Aufgaben, die in Kooperation mit Menschen durchgeführt werden können.

³⁴ Rao und Verweij 2017

³⁵ Groopman und Kaul 2017, Groopman und Wheelock 2017, Sahi und Kaul 2017

³⁶ PwC 2017

³⁷ Groopman und Kaul 2017

Abbildung 10: Anwendungsbranchen für Maschinelles Lernen³⁴


In der Robotik besteht die größte Herausforderung derzeit darin, in Robotern Adaptionenmechanismen zu implementieren, damit sie mit ihrer Umgebung und den Menschen in einer sicheren, anpassungsfähigen und flexiblen Art und Weise interagieren.³⁹ Die Fortschritte beim Deep Learning könnten in diesem Kontext entscheidende Vorteile bieten. Dazu bedarf es allerdings meist einer extrem großen Menge an Beispieldaten für das Trainieren der Modelle.

Bedeutend sind auch die Entwicklungen beim maschinellen Sehen, der maschinellen Wahrnehmung und Kommunikation. Maschinelles Lernen auf Daten von modernen IoT-Sensoren (Internet of Things), kombiniert mit Wartungsprotokollen und externen Quellen verbessert die vorausschauende Wartung, ermöglicht bessere Vorhersagen und damit die Vermeidung von Maschinenfehlern. Hier wird die Möglichkeit zur Steigerung der Anlagenproduktivität um bis zu 20 % gesehen, bei gleichzeitig sinkenden Wartungskosten um bis zu 10 %.⁴⁰

ML ist auch eine Schlüsseltechnik für das hochautomatisierte Fahren. Fahrerassistenzsysteme unterstützen die Steuerung und Navigation von Transportmitteln, können auf sich verändernde Umgebungen reagieren, die Bahn- und Bewegungsplanung

übernehmen und Kollisionen verhindern. Auch auf zukünftige Sharing-Konzepte mit autonomen Fahrzeugen und deren Management wird sich ML maßgeblich auswirken.⁴¹ Weitere Funktionalitäten ermöglichen das Kolonnenfahren, prädiktive Wartung, die Überwachung des Fahrzeug- und Fahrerzustandes sowie diverse Infotainment- und Komfortdienste. Während für die ersten Automatisierungsstufen bereits marktfähige Produkte existieren, steht teil-, hoch- und vollautomatisiertes Fahren im Fokus der aktuellen Forschung und Entwicklung. Vollautonomes Fahren, bei dem das Fahrzeug »vollumfänglich auf allen Straßentypen, in allen Geschwindigkeitsbereichen und unter allen äußeren Bedingungen die Fahraufgabe vollständig allein durchführen« kann, wird aktuellen Einschätzungen zufolge gegen 2025 erreicht werden.⁴² Bis dahin sind neben den technischen vor allem rechtliche Fragestellungen zu beantworten. Die weltweiten Umsätze mit Deep-Learning-Techniken in der Automobilindustrie in 2016 werden von Tractica-Experten auf 61,2 Mio Dollar eingeschätzt, 2025 werden Umsätze bis 1,4 Milliarden Dollar erwartet.⁴³

ML-gestützte Datenanalyse und intelligente, autonome Landmaschinen sowie Drohnen werden in der modernen Landwirtschaft (Precision Agriculture und Smart Farming)

38 Eigene Darstellung, basierend auf Marktprognosen, Interviews mit ML-Fachleuten und Teilnehmern des Validierungsworkshops.

39 Vgl. Stanford University 2016, S. 9.

40 McKinsey 2017

41 PwC 2017

42 Verband der Automobilindustrie e.V. 2015, BITKOM 2016.

43 Burger und Wheelock 2017

bereits eingesetzt, um die Produktivität, Nachhaltigkeit und Wettbewerbsfähigkeit zu steigern. Zu den Aufgaben intelligenter Drohnen gehören beispielsweise die Erfassung von Daten über Sensoren mit anschließender Auswahl gezielter Einsätze zur Schädlingsbekämpfung oder Düngung. Computer Vision, maschinelle Sensordatenfusion, Robotik und ML befähigen Maschinen zur intelligenten Erkennung, Identifizierung und Entscheidungsunterstützung bei der Wettervorhersage, Landnutzung und Lebensmittelsicherheit. Laut Prognosen werden die jährlichen Umsätze mit Deep-Learning-Software in der Landwirtschaft im Jahr 2025 bis zu 2,1 Mrd Dollar betragen.⁴⁴

In weiteren Branchen sind noch viele Anwendungsmöglichkeiten für ML vorhanden. Als attraktive Anwendungsfelder in der öffentlichen Verwaltung, die in Deutschland aktuell noch nicht im zentralen Blickfeld der Unternehmen stehen, nannten die Fachleute Prozessoptimierung, Predictive Policing und E-Government. Um die Potenziale des deutschen Forschungs- und Wirtschaftsstandorts im Bereich des Maschinellen Lernens weiter zu stärken, sind innovationsfördernde sozio-ökonomische, rechtliche und politische Rahmenbedingungen unverzichtbar.

44 Burger und Wheelock 2017

4 NEUE AUFGABEN FÜR DIE FORSCHUNG

Im globalen Wettbewerb gibt es also viele Gründe, ML-Techniken weiter zu verbessern und noch effektiver, effizienter, adaptiver und sicherer zu gestalten. Die größten Herausforderungen, die von den konsultierten Experten genannt wurden, betreffen die Datennutzung, den Ausbau der Fähigkeiten von ML-basierten Anwendungen und die Verbesserung ihrer Akzeptanz. Die folgende Tabelle gibt einen Überblick über die Forschungsziele, Forschungsansätze und die Einschätzung der zukünftigen Relevanz durch die befragten Fachleute.

Am wichtigsten ist demzufolge die Forschung zur besseren Nachvollziehbarkeit von ML-Anwendungen. Des Weiteren werden das Lernen mit zusätzlichem Wissen durch Einbeziehen von physikalischen, semantischen oder strukturellen Beschreibungen, sowie das Lernen mit wenigen Daten als wichtig angesehen. Für diese Themen hat das BMBF bereits Förderprogramme aufgelegt, die nach Einschätzung der Fachleute unbedingt fortgesetzt werden müssen. Dem Forschungsthema der Mensch-Maschine-Kollaboration wird eine steigende Bedeutung beigemessen, während der Aspekt der Anpassungsfähigkeit und Flexibilität aktuell als weniger wichtig erachtet wird.

Tabelle 9: Zukünftige Forschungsthemen und die Bewertung der Fachleute

Forschungsziele	Forschungsansätze	Relevanz (1 = höchste Relevanz)
Verbesserung der Akzeptanz		
<ul style="list-style-type: none"> Nachvollziehbarkeit 	<ul style="list-style-type: none"> Erklärbare KI Erkennung von Diskrimination Adversarial Training Robustes Lernen 	1
Ausbau der Fähigkeiten		
<ul style="list-style-type: none"> Lernen mit zusätzlichem Wissen 	<ul style="list-style-type: none"> Grey-Box-Modelle Lernen mit symbolischem Wissen 	2
<ul style="list-style-type: none"> Kollaboration 	<ul style="list-style-type: none"> Interaktives Lernen vom Menschen Metallernen (Auto-ML) 	4
<ul style="list-style-type: none"> Anpassungsfähigkeit und Flexibilität 	<ul style="list-style-type: none"> Multitask-Lernen Transfer-Lernen Lebenslanges Lernen Multimodales Lernen 	5
Datennutzung		
<ul style="list-style-type: none"> Lernen mit wenigen Daten 	<ul style="list-style-type: none"> Lernen aus Simulationen One-Shot- und Zero-Shot-Lernen Unüberwachtes Lernen von Labels 	3
<ul style="list-style-type: none"> Lernen mit sehr großen Datenmengen 	<ul style="list-style-type: none"> Verteilte Algorithmen Lernen aus Datenströmen Lernen in Quantencomputern 	6

4.1 Daten als Herausforderung

Als datengetriebene Technologie stößt ML an Grenzen, wenn Daten in noch größeren Mengen noch schneller anfallen und zeitgleich daraus gelernt werden soll, oder wenn aus sehr kleinen Datenmengen verlässlich gelernt werden soll. Im deutschen Kontext haben die Fachleute das Maschinelle Lernen mit wenigen Daten als noch wichtiger eingeschätzt, da hier in manchen Bereichen zu wenig brauchbare Daten vorliegen. Gleichzeitig wurde auf das sehr umfangreiche Hintergrund- und Expertenwissen vor allem in der deutschen Industrie hingewiesen, welches für das Lernen nutzbar gemacht werden sollte.

4.1.1 Nutzung großer Datenmengen

Insbesondere bei sensorischen Messungen in der vorausschauenden Maschinenüberwachung, bei Finanztransaktionen und anderen Prozessen fallen kontinuierlich extrem große Datenmengen an, die praktisch in Echtzeit ausgewertet werden müssen, ohne dass die Daten überhaupt gespeichert werden können. Hier bietet sich das sogenannte Online-Lernen an, das ohne die konventionelle Einteilung in Trainingsdaten für die Modellentwicklung und Testdaten für die Modellbewertung auskommt.

Während sich tiefe KNN hervorragend auf graphischen Prozessoren oder dedizierten Chips abbilden und verteilt lernen lassen, wird für etliche klassische Modelle weiterhin nach effizienten parallelen Implementierungen gesucht.

Ein Forschungsfeld, das wohl erst mittelfristig praktische Relevanz gewinnen wird, ist das Lernen in Quantencomputern. Da sich Quantencomputer aufgrund ihrer »nicht-klassischen« physikalischen Struktur fundamental von den heute üblichen Computern unterscheiden, können hier extrem viele Berechnungen parallel ablaufen. Dafür werden allerdings ganz neue ML-Algorithmen notwendig.

4.1.2 Lernen mit geringen Datenmengen

Gerade für Anwendungen, die in Deutschland von Interesse sind, liegt das Problem oftmals darin, dass nicht genügend, beziehungsweise nicht genügend brauchbare Daten verfügbar sind. In der Robotik, der industriellen Produktion, in medizinischen und sicherheitsrelevanten Anwendungen

treten manche Ereignisse nur selten auf, weshalb sie in den Daten unterrepräsentiert sind. Auch kann es aus Gründen des Datenschutzes oder Urheberrechts zu Restriktionen bei der Datennutzung kommen.

In manchen Fällen existieren zwar Daten, aber keine Labels. Unüberwachte Lernverfahren könnten hier helfen und fehlende Labels automatisch erzeugen. Für autonome Agenten, Fahrzeuge und Roboter, die beim bestärkenden Lernen Feedback zu ihren Aktionen benötigen, steigt das Interesse am Lernen in Simulationen, da hier genug Trainingsdaten aller Art generiert werden können.

Performantes Lernen mit wenigen Trainingsdaten ist ein noch offenes Forschungsfeld, dem eine große Bedeutung zugesprochen wird. Idealerweise möchte man Maschinen dazu befähigen, anhand weniger Beispiele oder durch die Kombination bekannter Beispiele zu lernen. Diese Fähigkeit in ML-Anwendungen zu implementieren wird als »One-Shot« – oder gar »Zero-Shot«-Lernen bezeichnet.

4.2 Ausbau der Fähigkeiten

Eng verbunden mit dem Lernen aus wenigen Daten ist das Ziel, ML-Modelle leichter an neue Kontexte anpassen zu können. Heutige Anwendungen kommen noch nicht wirklich zuverlässig in Situationen zurecht, die außerhalb ihrer begrenzten Trainingskonditionen liegen. Die oftmals erstaunlichen Leistungen, die im Labor demonstriert werden, funktionieren unter Realbedingungen oft erheblich schlechter.

4.2.1 Anpassungsfähigkeit und Flexibilität

ML-Anwendungen werden flexibler, wenn im Modell vergangene Informationen abgespeichert und bei Bedarf zielgerichtet wieder abgerufen werden können. Bei starken Veränderungen tendieren KNN jedoch noch dazu, bereits Gelerntes wieder zu vergessen. Diesem sogenannten katastrophalen Vergessen versuchen neue Forschungsansätze entgegen zu wirken.

Ein Ansatz besteht darin, das Neusetzen von Gewichten in »erinnerungswürdigen« Teilen des Netzes zu verlangsamen.⁴⁵

Beim Multitask-Lernen wird versucht, verschiedene Aufgaben gleichzeitig auf einer gemeinsamen Repräsentation zu lernen, die dadurch tragfähiger wird. Das Transfer-Lernen zielt hingegen darauf ab, in einem KNN Teilbereiche zu finden, die

45 Kirkpatrick et al. 2017

bereits für eine bestimmte Aufgabe trainiert worden sind, um sie für eine andere, verwandte Aufgabe wieder zu verwenden. Ferner beginnt die Forschung damit, Maschinen »lebenslang lernen« zu lassen, also ihr Modell fortlaufend an Veränderungen anzupassen.

Ein anderer Ansatz orientiert sich daran, dass Menschen zur besseren Situationseinschätzung meist mehrere Informationskanäle – auditive, visuelle und haptische – gleichzeitig nutzen. Ähnliches soll auch im ML gelingen, wobei die Herausforderung vor allem in der semantischen Verknüpfung dieser unterschiedlichen Signale liegt.

4.2.2 Lernen mit zusätzlichem Wissen

In vielen Anwendungsbereichen nutzen Fachleute eigene Formalisierungen, um typische Eigenschaften oder das Verhalten der untersuchten Systeme zu beschreiben. Solches Zusatzwissen ist nicht immer vollständig und kann datengetrieben verbessert werden. Im Ingenieursbereich wird das physikalische Verhalten von Maschinen und Anlagen meist durch umfangreiche Differentialgleichungssysteme ausgedrückt, die dann als sogenannte »White-Box«-Modelle zur Simulation eingesetzt werden. Dagegen bezeichnen Ingenieure KNN und andere datengetriebene ML-Modelle, die aus Beispieldaten eine Funktion von Ein- zu Ausgabevektoren lernen, als »Black-Box«-Modelle. Beide haben ihre jeweiligen Vor- und Nachteile im Hinblick auf Erstellungsaufwand, Genauigkeit und Nachvollziehbarkeit, so dass ein hybrider »Grey-Box«-Ansatz enorme Vorteile verspricht.

Ein anderes hybrides Prinzip nutzt symbolisches Wissen über Objekte und ihre Beziehungen, das in Wissensgraphen formalisiert wird. Je vollständiger ein Wissensgraph ist, desto komplexere Zusammenhänge lassen sich darin verfolgen und desto anspruchsvollere Fragen beantworten. Dabei steigt allerdings auch der Erstellungsaufwand drastisch. Erste gute Lernverfahren versuchen, Wissensgraphen automatisch zu vervollständigen, indem sie Relationen zwischen Knoten vorhersagen, Knoten identifizieren, die dasselbe Objekt beschreiben, und einem Knoten eine Klasse zuordnen.

Die Einbeziehung von Wissensgraphen, logischen Regeln und White-Box-Elementen in das Training eines ML-Modells kann auch dazu beitragen, die ML-Anwendung insgesamt effizienter, zuverlässiger und sicherer zu gestalten, da von Anfang an Domänen-, Erfahrungs- oder Expertenwissen integriert wird.

4.2.3 Kollaboration

Ein großes Ziel für zukünftige intelligente Anwendungen ist eine möglichst flexible Kollaboration zwischen Mensch und Maschine. Einerseits soll die Maschine aus der Interaktion mit dem Menschen dazulernen und nicht immer wieder die gleichen Fehler machen. Bei unsicheren Antworten könnte sie vom Experten eine Bestätigung oder die Angabe eines Labels anfordern. Andererseits sollen die Aktionen und Antworten der Maschine für den Menschen nachvollziehbar sein.

Eine andere Art der Zusammenarbeit liegt in der Unterstützung von Datenwissenschaftlern. Der Workflow von einer initialen Fragestellung bis zum gut trainierten Modell beinhaltet eine Reihe von Arbeitsschritten, die mehrfach durchlaufen werden müssen, bis die gewünschte Qualität erreicht ist. »Metalernen« oder »Auto-ML« entwickelt Algorithmen, die lernen, selber ML-Modelle zu trainieren, wodurch der Aufwand für Data Scientists reduziert wird.

4.3 Nachvollziehbarkeit, Fairness und Sicherheit

In Fällen, in denen die Gesetzgebung verlangt, dass automatisierte Entscheidungen begründet werden und die Betroffenen beispielsweise nicht aufgrund ihres Geschlechts oder ihrer Konfession benachteiligt werden, sind Nachvollziehbarkeit, Fairness und Sicherheit einer ML-Anwendung essenziell und erhöhen außerdem die Akzeptanz.

4.3.1 Nachvollziehbarkeit, Erklärbarkeit und Transparenz

Die Nachvollziehbarkeit von ML-Anwendungen ist aus Sicht der konsultierten Fachleute das wichtigste Forschungsziel. Für diese Thematik hat sich der Begriff »Explainable AI« (XAI oder erklärbare KI) etabliert. Es wird dabei zwischen Transparenz und Erklärbarkeit unterschieden. Transparenz bedeutet, dass das Verhalten der Anwendung vollständig nachvollziehbar ist. Praktisch ist diese Forderung jedoch nur schwer erfüllbar, da viele Modelle notwendigerweise sehr komplex sind. Erklärbarkeit hingegen bedeutet, dass für eine konkrete Einzelentscheidung der Anwendung die wesentlichen Einflussfaktoren aufgezeigt werden können, was im Sinne der EU-Datenschutzgrundverordnung ausreichend ist. Technisch ist sie zudem deutlich einfacher zu erfüllen als Transparenz. Eine wissenschaftliche Herausforderung besteht darin, die Eingabedaten zu Konzepten zu abstrahieren, die für den Menschen sinnvoll sind. Andere prototypische Ansätze liefern repräsentative Einzelfälle zur Erklärung von Entscheidungen.

4.3.2 Fairness und Diskriminierungsfreiheit

Das Ergebnis einer ML-Anwendung kann als unethisch und diskriminierend erachtet werden, wenn beispielsweise Daten über Ethnie, Religion, Geschlecht oder Alter in unerlaubter oder falscher Form zur Entscheidungsfindung herangezogen werden. Hier ist es notwendig, bereits in den Trainingsdaten für hinreichende Anonymisierung und Repräsentativität zu sorgen und besonders sorgsam darauf zu achten, dass die Labels die richtigen Antworten darstellen. Ebenfalls kann es sinnvoll sein, von vornherein in das Verfahren Beschränkungen für erlaubte Modelle zu integrieren. Eine technische Herausforderung besteht auch darin, den rechtlichen Begriff der Diskriminierung anwendungsabhängig in eine mathematische Definition zu überführen, die algorithmisch überprüft und umgesetzt werden kann.

4.3.3 Sicherheit und robuste Lernverfahren

Eine Maßnahme zur Erhöhung der Sicherheit in ML-Systemen ist der Einbau von Sicherheitsspannen. Ein wichtiger Aspekt ist hier die Robustheit, also die Gewährleistung, dass kleine Änderungen in der Eingabe auch nur kleine Änderungen im Ergebnis bewirken. 2017 machten Beispiele Schlagzeilen, wo tiefe KNN durch eine für den Menschen unmerkliche Veränderung weniger Pixel in einem Bild gravierende Fehlklassifikationen lieferten. So wurden für den Menschen unmerklich veränderte Stoppschilder vom System nicht mehr als solche erkannt und einige Gewehre als Hubschrauber kategorisiert^{46,47}. Dies ist ein ernsthaftes Problem mit sicherheitsrelevanten Implikationen. Ein Ansatz, dem entgegen zu wirken, ist das sogenannte Adversarial Training, bei dem die Modelle absichtlich mit störsignalbehafteten Daten trainiert werden, so dass sie im Einsatz robuster generalisieren.

46 Evtimov et al. 2017

47 Matsakis 2017

5 FÄHIGKEITEN UND REIFEGRADE

Maschinelles Lernen ist eine Schlüsseltechnologie, um Maschinen mit neuen Fähigkeiten auszustatten, die in unterschiedlichen Anwendungsgebieten zum Einsatz kommen können und jeweils andere FuE-Ansätze im Fokus haben. Die folgende Tabelle gibt eine Übersicht zu ML-basierten

Fähigkeiten, ihrem Nutzen, entsprechenden FuE-Ansätzen und Anwendungsbereichen. Die drei Farbabstufungen drücken eine Einschätzung zum derzeitigen Reifegrad aus. Dabei ist zu beachten, dass bei allen Lernaufgaben gute Ergebnisse immer von einer guten Datenlage abhängen.

Tabelle 10: ML-basierte Kompetenzen, Forschungsansätze, Einsatzgebiete und Reifegrad

Fähigkeit	Nutzen	
Gruppen ähnlicher Daten bilden	Diese Fähigkeit ermöglicht bspw. das Erkennen von Mustern und hilft, Strukturen in großen Datenmengen zu erkennen.	
Objekte klassifizieren	Diese Fähigkeit ermöglicht das Einordnen von Beispielen für die weitere Bearbeitung, um Entscheidungen zu treffen oder Maßnahmen einzuleiten.	
Werte schätzen und vorhersagen	Hier werden lineare oder komplexere Zusammenhänge erkannt und für Vorhersagen über künftige Zustände bzw. Ereignisse genutzt.	
Erfolgversprechende Aktionen für einen Agenten auswählen	Agenten und Roboter können anhand von Feedback lernen, welche Aktionen, Spielzüge etc. die besten Resultate erzielen können. Das ist eine Alternative zum expliziten Planen und Adaptieren von Handlungsfolgen.	
Bilder erkennen	Auf Bildern werden Objekte lokalisiert, klassifiziert und ggf. Individuen erkannt.	

Legende:

■ Stufe 1: Inzwischen gut etabliert
■ Stufe 2: Demonstratoren vorhanden, Forschung für komplexere Anwendungen unbedingt erforderlich
■ Stufe 3: Noch in früher FuE-Phase

	FuE-Ansätze	Mögliche Anwendungen	Reife-grad
	<ul style="list-style-type: none"> ■ Clustering ■ Tiefe neuronale Netze 	<ul style="list-style-type: none"> ■ Marketing: Kundensegmentierung, Zielgruppenübersicht 	1
	<ul style="list-style-type: none"> ■ Entscheidungsbäume ■ Stützvektormaschinen ■ Bayessche Netze ■ Logistische Regression 	<ul style="list-style-type: none"> ■ Datenfiltersysteme ■ Sortieraufgaben (z. B. Güteklassifizierung in der Produktion) ■ Marketing (z. B. Matching von Kunden und Waren) 	1
	<ul style="list-style-type: none"> ■ Lineare Regression ■ Regressionsbäume (CART) ■ Entscheidungsbäume 	<ul style="list-style-type: none"> ■ Generierung von Prognosen (Stau, Angebot- und Nachfrage) ■ Anomalie-Detektion ■ Maschinen-/Anlagenoptimierung ■ Vorausschauende Wartung ■ Finanz-, Versicherungs- und Rechtswesen ■ Medizin, Chemie, Materialforschung (Entdeckung neuer Molekularkombinationen etc.) ■ Steuerungsaufgaben 	1
	<ul style="list-style-type: none"> ■ Bestärkendes Lernen ■ Q-Lernen mit tiefen neuronalen Netzen 	<ul style="list-style-type: none"> ■ Robotik (z. B. um das optimale Greifen unterschiedlicher Objekte zu lernen) ■ Autonomes Fahren (z. B. um in Simulationen erwünschte und unerwünschte Aktionen unterscheiden zu können) ■ Spieleindustrie ■ Konsumelektronik 	2
	<ul style="list-style-type: none"> ■ Tiefe neuronale Netze 	<p>Alle Bereiche, in denen Objekterkennung von Nutzen ist, insbesondere</p> <ul style="list-style-type: none"> ■ Automotive (Straßenschildidentifikation etc.) ■ Industrielle Produktion/Industrierobotik ■ Medien (Suche) ■ Medizin (Radiologische Diagnostik) ■ Sicherheit (Videoüberwachung) 	1

Fähigkeit	Nutzen	
Sprache erkennen	Audiosignale werden als Sprache erkannt und in Text umgewandelt. Der Sprecher und seine Emotionen können identifiziert werden.	
Informationen aus Texten extrahieren und einfachen Aufforderungen nachkommen	Aus Texten werden bestimmte Informationen extrahiert, z. B. Namen, Adressen, Marken. Emotionen können anhand der Wortwahl identifiziert werden. Einfache Befehle oder Fragen werden erkannt und ausgeführt bzw. beantwortet. Äußerungen und Texte werden übersetzt.	
Sprache und Text verstehen sowie kommunizieren	Hier wird nicht nur ein Wort erkannt, sondern auch eine semantische Einordnung geleistet. Sätze werden in Bezug zu früheren Äußerungen gesetzt und Dialoge fortgesetzt.	
Bild und Video semantisch und im Kontext verstehen	Bei Bildern und Bildfolgen geht es nicht nur darum, einzelne Objekte zu identifizieren, sondern die Szene zu verstehen. Wer interagiert mit wem, was passiert gerade, was könnte als nächstes geschehen?	
Multimodale Inhalte kombinieren	Hier geht es um die Fähigkeit, zusammengehörige Text-, Bild-, Audiodaten in Bezug zu setzen, etwa die Aufnahme von Kamera und Mikrophon oder ein radiologisches Bild mit einem dazugehörigen wissenschaftlichen Report.	
Neue Inhalte generieren	Maschinen können inzwischen sogar »kreative« Aufgaben durchführen, wie bspw. das Schreiben von Gedichten, das Malen von Bildern und Komponieren von Musikstücken, die Animation von Figuren in digitalen Spielen und die Zusammenfassung von Meldungen zu einem Bericht (Robo-Journalismus).	
Lernen mit zusätzlichem Wissen kombinieren	Wenn physikalische Gesetze, endliche Automaten, logische Regeln und allgemein das formalisierte Wissen von Fachleuten mit ML-Modellen kombiniert werden, können ML-Anwendungen effizienter, verständlicher, verlässlicher und kontrollierbarer gestaltet werden.	
Lernen mit vielen Daten	In vielen Fällen sind die Trainingsdaten so umfangreich, dass ein sequentieller Lernalgorithmus zu lange dauern würde. Hier helfen nur parallelisierte Lernalgorithmen, wie die tiefen neuronalen Netze. Algorithmen, die ohne Speicherung aus vorbeifließenden Daten lernen, sind oft die einzige Möglichkeit, aus sehr großen Datenströmen zu lernen.	

	FuE-Ansätze	Mögliche Anwendungen	Reife-grad
	<ul style="list-style-type: none"> ■ Tiefe neuronale Netze 	Alle Bereiche, in denen Spracherkennung von Nutzen ist, insbesondere <ul style="list-style-type: none"> ■ Konsumelektronik ■ Automobil ■ Spieleindustrie ■ Medizin ■ Medien und Entertainment 	1
	<ul style="list-style-type: none"> ■ Tiefe Neuronale Netze ■ Textmining ■ Wissensgraphen 	<ul style="list-style-type: none"> ■ Marktforschung ■ Medizin (Forschung und Diagnostik) ■ Informationssysteme ■ Übersetzungen ■ Marketing (Sentimentanalyse) ■ Business Services (Klassifikation von Dokumenten) 	1
	<ul style="list-style-type: none"> ■ Tiefe Neuronale Netze ■ Wissensgraphen ■ Kombinationen mit symbolischen Modellen 	<ul style="list-style-type: none"> ■ Kundendienst ■ E-Commerce, Sales ■ Wissenschaftliche Arbeit ■ Konsumelektronik 	3
	<ul style="list-style-type: none"> ■ Tiefe Neuronale Netze ■ Kombination von Tiefen Neuronalen Netzen und symbolischen Verfahren 	Alle Bereiche, in denen ein Lageverständnis von Relevanz ist <ul style="list-style-type: none"> ■ Autonomes Fahren (Situationserkennung) ■ Security-Anwendungen / Überwachung ■ OP-Unterstützung in der Medizin 	2
	<ul style="list-style-type: none"> ■ Tiefe Neuronale Netze ■ Multimodales Lernen 	<ul style="list-style-type: none"> ■ Medizin und Gesundheitswesen ■ Wissenschaft ■ Medien und Entertainment ■ Robotik 	2
	<ul style="list-style-type: none"> ■ Generative tiefe Neuronale Netze ■ Probabilistische Modelle 	<ul style="list-style-type: none"> ■ Journalismus ■ Entertainment, Film, Kunst, Musik, Theater ■ Spieleindustrie ■ Simulation 	3
	<ul style="list-style-type: none"> ■ Einbeziehung und Generierung von symbolischem Wissen ■ Grey-Box-Modelle ■ Regellernen ■ Lernen mit Wissensgraphen 	Überall dort, wo physikalische Gesetze eine bedeutende Rolle spielen oder intrinsisches Expertenwissen von zentraler Bedeutung ist. <ul style="list-style-type: none"> ■ Industrielle Produktion ■ Medizin- und Gesundheitswesen 	3
	<ul style="list-style-type: none"> ■ Tiefe Neuronale Netze ■ Verteilte Lernalgorithmen ■ Lernen aus Datenströmen ■ Repräsentationslernen 	<ul style="list-style-type: none"> ■ Überwachungsaufgaben (Produktionsprozesse, Finanzaktivitäten, Videoüberwachung, kritische Infrastrukturen) ■ Empfehlungssysteme 	1

Fähigkeit	Nutzen	
Lernen mit wenigen Daten	Wenn lediglich wenige oder wenig brauchbare Trainingsdaten zur Verfügung stehen, möchte man trotzdem bestmöglich daraus lernen.	
Anpassung an eine veränderliche Umgebung	Gelernte Modelle, die für die Lösung einer Aufgabe erfolgreich waren, dienen als Ausgangspunkt für die Lösung neuer, aber ähnlicher Aufgaben mit deutlich reduziertem Trainingsaufwand.	
Automatisiertes Lernen	Der Entwicklungsaufwand soll durch Teilautomatisierung in der Modellentwicklung verringert werden. Um ML schneller in die Breite zu tragen, müssen Data Scientists soweit wie möglich entlastet werden.	
Transparente, nachvollziehbare und robuste Modelle	In viele Fällen möchten oder müssen Menschen verstehen, wie eine ML-basierte Anwendung zu einer Entscheidung gekommen ist und welche Daten und Verknüpfungen hierfür herangezogen worden sind. Hinreichende Robustheit gegen Störungen, das Einhalten von Einschränkungen und das explizite Berücksichtigen von Kompetenzgrenzen stärken das Vertrauen der Nutzer in die ML-Anwendung.	

	FuE-Ansätze	Mögliche Anwendungen	Reife-grad
	<ul style="list-style-type: none"> ■ Lernen von Labels ■ Lernen in Simulationen ■ One-Shot-Lernen ■ Transfer-Lernen 	<ul style="list-style-type: none"> ■ Medizin- und Gesundheitsanwendungen ■ Gefahrenabwehr (Produktionsprozesse, Finanzaktivitäten, Videoüberwachung, kritische Infrastrukturen) ■ Industrielle Produktion 	2
	<ul style="list-style-type: none"> ■ Transfer-Lernen ■ Lebenslanges Lernen ■ Multitask-Lernen ■ Interaktives Lernen 	<ul style="list-style-type: none"> ■ Insbesondere in der Robotik (zur Gestaltung von flexibleren Robotern, bspw. im Service-Bereich) 	3
	<ul style="list-style-type: none"> ■ Auto-ML 	Alle praktischen Anwendungen	3
	<ul style="list-style-type: none"> ■ Explainable AI ■ Adversarial ML ■ Robuste Lernverfahren ■ Lernen von Kompetenzgrenzen ■ Lernen unter Beschränkungen 	<p>Insbesondere dort, wo der Gesetzgeber eine Nachvollziehbarkeit verlangt oder es anderweitig sehr wichtig für die Herstellung von Vertrauen in die Anwendung ist, v.a.</p> <ul style="list-style-type: none"> ■ Finanz- und Versicherungs- sowie Rechtswesen ■ Medizin-/Gesundheitswesen ■ Öffentliche Verwaltung 	2

6 RAHMENBEDINGUNGEN FÜR MASCHINELLES LERNEN

Rahmenbedingungen definieren wir als übergeordnete rechtliche, gesellschaftliche und politische Aspekte, die im Sinne von Leitplanken die Forschung zu ML und die Anwendungen von ML-basierten Produkten und Dienstleistungen einbetten. Im Folgenden werden jene aufgeführt, die von den konsultierten Fachleuten auf unserem wissenschaftlichen Validierungsworkshop priorisiert wurden. Diese werden durch Sekundärliteratur angereichert.

6.1 Aus- und Weiterbildung

Der Bedarf an Fachkräften für digitale Techniken und ML ist sehr groß. In Deutschland reichen die derzeit ausgebildeten Akademiker nicht aus, um die große Nachfrage abzudecken. Aktuell fehlen rund 85 000 Akademikerinnen und Akademiker mit fortgeschrittenen Datenanalyse- und Big-Data-Kenntnissen, besonders im Medizin- und Ingenieursbereich. Die Breite der ML-Ausbildung wird von den befragten Fachleuten als ein entscheidender Wettbewerbsfaktor angesehen, da oftmals sowohl Ingenieurs- als auch ML-spezifische Kompetenzen benötigt werden, wie für das in Deutschland bedeutende Lernen mit »Grey-Box«-Modellen. Daneben werden rund 10 000 IT-Spezialfachkräfte in den Bereichen Big Data, Advanced Analytics, Business Analytics und Data Science benötigt.⁴⁸ Die Hochschulen in Deutschland reagieren nur zögerlich auf den Bedarf des Arbeitsmarktes: von den bundesweit insgesamt 18 467 Studiengängen in 2016/2017 hatten lediglich 23 eine explizite Spezialisierung auf Big Data, Data Science und Advanced Analytics/Business Analytics.⁴⁹ Der globale Wettbewerb einerseits, aber auch die prognostizierte, positive Marktentwicklung für KI- und ML-Produkte und -Dienstleistungen andererseits⁵⁰ verschärfen den Mangel in Deutschland weiter.⁵¹ Zudem verfügen Universitäten und Forschungseinrichtungen hierzulande im globalen Vergleich oftmals über relativ wenig Sichtbarkeit und finanzielle Anreize.⁵²

Zusätzlich zur Förderung der Vermittlung KI-basierter Kompetenzen in der Breite sollten nach Einschätzung der konsultierten Experten sowohl mehr IT-Spezialfachkräfte in Deutschland ausgebildet als auch global rekrutiert werden, um die Nachfrage zu decken.

Auch Aus- und Weiterbildungsangebote sollten im Hinblick auf den breiten Erwerb von KI-basierten Kompetenzen stärker interdisziplinär orientiert sein. So waren sich die befragten Fachleute einig, dass insbesondere juristische Aspekte in die ML-bezogene Informatikausbildung miteinbezogen werden sollten. Dadurch können gesetzliche Vorgaben beim Entwurf und der Implementierung ML-basierter Anwendungen leichter berücksichtigt werden. In diesem Kontext ist auch die Integration ethischer Ausbildungsinhalte wichtig, da maschinelles Fehlverhalten der Wahrung ethischer Absichten zuwiderlaufen kann, wie die Diskussion um die sogenannte Dilemmasituation im (voll-)automatisierten Straßenverkehr zeigt.⁵³

Aufgrund des disruptiven Potenzials von ML und KI für viele Branchen und Tätigkeitsprofile sollten den Fachleuten zufolge ML-Wissen und -Kompetenzen in jedem Aus- und Weiterbildungscurriculum vermittelt werden. Derartiges Wissen wird in Betrieben nicht nur durch interne Weiterbildungsprogramme aufgebaut, sondern oft auch extern durch Kooperation und Akquise kreativer Start-ups mit spezifischen ML-Lösungen erworben.⁵⁴

6.2 Transfer in die Praxis

Wie bereits aus den Patentanalysen ersichtlich, scheinen insbesondere KMU Aufholbedarf beim Einsatz von ML-Techniken zu haben. Nach Einschätzung der konsultierten Fachleute zeigen KMU vielfach Interesse, sobald sie konkrete Einsatzmöglichkeiten mit unternehmerischem Mehrwert aufgezeigt bekommen.

48 Stifterverband und McKinsey, 2017

49 Stifterverband und McKinsey, 2017

50 McKinsey Global Institute, 2017

51 Economist, 2016

52 Lakemeyer, G., 2017

53 The Royal Society, 2017

54 VDMA, 2017

Daher sollten Fördermaßnahmen Führungskräfte und Mitarbeitende allgemein für den Einsatz von ML fit machen, indem sie zum Beispiel mehr über den Einsatz und den Nutzen von ML-basierten Techniken für Geschäftsmodelle informieren. Existierende Maßnahmen zur strategischen Unternehmensförderung – die als noch ausbaufähig angesehen werden – sprechen aber eher jüngere Unternehmen und Start-ups an und weniger die etablierten KMU.

Der Transfer von Wissen zu KI zwischen den Akteuren und im Besonderen zu den KMU kann dabei auch über Dialogplattformen, wie beispielsweise die Plattform »Lernende Systeme«, erfolgen.⁵⁵

Angesichts der in Deutschland als gut eingeschätzten Position in der theoretischen und der ML-Grundlagenforschung⁵⁶ sollte der Anwendungsbezug in der (Grundlagen-)Forschung gestärkt werden, um noch mehr als bisher Ideen, Ansätze und Methoden zu fördern, die in Anwendungen münden können. Dies kann durch gezielte Transferprojekte in Kooperation zwischen Grundlagenforschung und Anwendung erfolgen. In öffentlich finanzierten Forschungsprojekten sollte der Marktbedarf bzw. die Umsetzung am Markt stärker herausgearbeitet werden. Die Fachleute betonen, dass gezielte Fördermaßnahmen zur Stärkung der Anwendungsreife sehr bald einsetzen müssen, damit deutsche Technologieanbieter im globalen Wettlauf mithalten können. Auch vor dem Hintergrund der Größenordnungen der derzeit bei den Mitbewerbern China, Japan und USA anlaufenden KI-Fördermaßnahmen⁵⁷ könnten die Kunden künftig vermehrt auf US-amerikanische oder asiatische Produkte und Dienstleistungen zurückgreifen. Dies gefährdet langfristig die Wettbewerbsfähigkeit besonders in deutschen Schlüsselbranchen wie Medizin, industrieller Produktion und Maschinenbau und wird durch den zugleich einhergehenden Verlust an Datenhoheit verstärkt.

6.3 Datenverfügbarkeit und Governance

Die Verfügbarkeit großer Datenmengen ist für das Maschinelle Lernen derzeit noch essenziell, besonders für die tiefen Lernverfahren. Führende US-amerikanische und chinesische B2C-Unternehmen wie Google, Facebook, Amazon, Baidu oder Alibaba verfügen über große Datenmengen durch ihre globale

Nutzerschaft. In Deutschland hingegen stehen aufgrund der stärkeren produktionsorientierten Industriestruktur einerseits, sowie strengerer Regelungen zum Datenschutz andererseits, weniger bzw. andersartige Daten zur Verfügung.

Den konsultierten Fachleuten zufolge mangelt es in Deutschland allgemein an der Datenverfügbarkeit. Hier besteht Handlungsbedarf, sowohl bei öffentlich-geförderten Forschungsprojekten als auch entsprechenden privatwirtschaftlichen Aktivitäten.

In diesem Zusammenhang sollte die Bereitstellung von »Open Data«, also offen zugänglichen Daten, die von jedem frei genutzt, weiterverbreitet und weiterverwendet werden dürfen, laut den befragten Expertinnen und Experten stärker gefördert werden. Prinzipiell werden öffentliche Einrichtungen als wichtige Lieferanten von »Open Data« gesehen. Außerdem könnte in öffentlich geförderten Forschungsprojekten das Teilen der gewonnenen Daten explizit eingefordert werden, wie es die Pilotinitiative »Open Research Data« der EU-Kommission vornimmt.⁵⁸

Neben »Open Data« spielt die Veröffentlichung neuartiger Daten eine große Rolle im Transfer von ML-basierten Anwendungen in den Markt. Hierfür ist besonders der Zugang zu neuartigen Datenbeständen essenziell zur Sicherung des Wettbewerbsvorsprungs bei ML-basierten Systemen. Denn werden neu gewonnene Daten publiziert, entstehen innerhalb kurzer Zeit (im Schnitt innerhalb von drei Jahren) neue Anwendungen. Im Gegensatz dazu münden Veröffentlichungen einer neuen ML-Methodik statistisch gesehen wesentlich langsamer in neue Anwendungen (im Schnitt 18 Jahre).⁵⁹

Die branchenübergreifende Nutzung von Daten aus den Unternehmen bietet große Potenziale für neue ML-basierte Geschäftsmodelle. Gerade Daten zum Kunden- und Maschinenverhalten werden von den Unternehmen ungern geteilt, weil sie dem Ausbau der eigenen Wettbewerbsfähigkeit dienen sollen. Dies benachteiligt KMU, die zumeist aufgrund ihrer Größe und Struktur über weniger Daten verfügen⁶⁰. Entsprechende Regelungen zum institutionenübergreifenden Austausch der Daten werden daher von den Experten als wichtig eingeschätzt.

55 EFI, 2018

56 EFI, 2018

57 EFI, 2018

58 <https://www.openaire.eu/what-is-the-open-research-data-pilot> (zuletzt geprüft am 20.02.2018)

59 <https://www.kdnuggets.com/2016/05/datasets-over-algorithms.html> (zuletzt geprüft am 20.02.2018)

60 VDMA, 2017

Derartige Governance-Modelle für den Datenaustausch sollten nach Einschätzung der befragten Fachleute die Sicherheit und Kontrollierbarkeit des Dateneigentümers gewährleisten. Oftmals können Governance-Modelle nur sektorspezifisch gestaltet werden, insbesondere im Gesundheits- und Produktionsbereich.⁶¹ Unabhängige Instanzen als Treuhänder, die den Zugang zu den Daten kontrollieren und gewährleisten, werden zunehmend nachgefragt. Modelle wie der Industrial Data Space⁶², wo die Unternehmen, die ihre Daten für digitale Dienste bereitstellen möchten, stets die Kontrolle über ihre Daten behalten und ihre Datenschutzvorgaben durchsetzen können, sind laut Einschätzung der Experten ein gutes Beispiel für die Sicherheit und Kontrollierbarkeit des Datenaustausches. Eine weitere Idee ist ein »Datenspendeausweis« für das Gesundheitswesen, der festhalten sollte, welche Daten eine Person für eingrenzbar wissenschaftliche oder medizinische Zwecke freigeben möchte, was zur Beschleunigung der medizinischen Forschung und Therapie beitragen könnte.

Neben der Quantität an Daten ist auch die Qualität, speziell die Vollständigkeit, Korrektheit und Dokumentation der Herkunft, von hoher Bedeutung für ML-Anwendungen. Dies erfordert eine gute Auf- und Vorbereitung der Daten. Die Fachleute haben darauf hingewiesen, dass die sehr ressourcenintensive Tätigkeit der Datenkuration im wissenschaftlichen Umfeld kaum honoriert wird. Es wird vorgeschlagen, die Datenarbeit explizit in Publikationen und akademischen Arbeiten zu würdigen, zum Beispiel in dem Zitiervorschlag zu einer Publikation. Als weitere Maßnahme fördern Standardisierungen die Vergleichbarkeit und Validierung von Modellen. Sie können sich auf Datenformate, aber auch auf Anforderungen an trainierte Modelle oder die Güteklasse von Resultaten beziehen. So können anwendungsbezogene Mindeststandards für Zuverlässigkeit, Robustheit, Performanz und Repräsentativität festgelegt werden. Qualitätskriterien für Datenbestände sollten über Metadaten definiert werden, um so den Austausch und (kommerziellen) Handel mit Datenbeständen zu erleichtern. Dokumentierte Trainingsdatenbestände und zertifizierte Validierungsdatenbestände dienen

der Nachvollziehbarkeit der Modelle im Einsatz,⁶³ erleichtern den Nachweis, dass automatisierte Entscheidungen im Einklang mit der Datenschutzgrundverordnung getroffen werden⁶⁴ und können das Vertrauen in ML-basierte Produkte und Dienstleistungen erhöhen.^{65,66}

6.4 Rechtliche, ethische und soziale Gestaltung

ML-Systeme werfen rechtliche Fragen auf, die in der Gesellschaft diskutiert werden sollten mit dem Ziel, einen akzeptierten Rechtsrahmen für zukünftige Entwicklungen zu schaffen. Zugleich sind die sozialen und ethischen Fragen des Einsatzes von ML entscheidend für das Vertrauen in ML-basierte Lösungen beim Nutzer. Maßstäbe für den verantwortungsvollen Einsatz von ML-Technologien müssen in vielen Fällen anwendungsspezifisch getroffen werden.⁶⁷

Rechtssicherheit in Bezug auf die Datenhoheit ist von großer Bedeutung für ML⁶⁸ und sollte nicht nur auf Daten beschränkt sein, die bereits heute von Unternehmen und Wissenschaftseinrichtungen erfasst werden. Der Rechtsrahmen sollte auch die Hoheit über zukünftig erfasste, neuartige Daten regeln, und zwar in Bezug auf die Erhebung, die Zugriffsrechte und die sichere Verarbeitung, Speicherung und Verteilung der Daten. Hier können Zielkonflikte bestehen zwischen dem Schutz personenbezogener oder personenbeziehbarer Daten und den Nutzungsmöglichkeiten für ML, die sich aus dem organisationsübergreifenden Datenaustausch ergeben.⁶⁹

Eine Weiterentwicklung des Rechtsrahmens ist ebenfalls erforderlich für maschinelle Entscheidungsprozesse im Hinblick auf das Haftungsrecht. Es ist zu klären, in welchem Umfang Entscheidungskompetenzen an automatisierte ML-Anwendungen abgegeben werden können und sollten.⁷⁰ ML-Anwendungen werden dann verstärkt den Weg in den Markt finden, wenn haftungsrechtliche Verantwortungen der Hersteller, Betreiber und Nutzer ML-basierter Systeme geklärt sind und das Risiko ML-basierter Anwendungen versicherbar wird. Insbesondere bei menschenähnlichen Dienstleistungen

61 The Royal Society, 2017

62 PwC, 2017; Fraunhofer-Gesellschaft, 2017

63 Fachforum Autonome Systeme im Hightech-Forum, 2017

64 Vgl. §13f, EU Datenschutz-Grundverordnung (DSGVO)

65 National Science and Technology Council, 2016a

66 Campolo, A.; Sanfilippo, M.; Whittaker, M.; Crawford, K., 2017

67 The Royal Society, 2017

68 VDMA, 2017

69 Fachforum Autonome Systeme im Hightech-Forum, 2017

70 VDMA, 2017

wie im Gesundheitswesen sollte die Rechtssicherheit für alle Beteiligten sichergestellt werden.⁷¹ Im Gewährleistungsrecht⁷² sind Verantwortlichkeiten für die korrekte Ausführung von Sicherheits- und Funktionsupdates zu klären, ebenso wie Fragen der Verantwortung im Falle von Fehlern.⁷³ Dazu gehört auch die (kartell-)rechtliche Beurteilung ML-basierter Markthandlungen, etwa auf Online-Buchungsplattformen. Hierfür muss klar definiert sein, wer diese Handlungen und die Algorithmen dahinter verantwortet.

Die Wahrung ethischer Prinzipien und Normen ist für die Akzeptanz bei den Anwendern zentral. Insofern muss gewährleistet werden, dass ML-Anwendungen anerkannte ethische Prinzipien nicht verletzen, wie eine Diskriminierung aufgrund bestimmter Persönlichkeitsmerkmale. Die Möglichkeit, dass ML-basierte vollautomatisierte Systeme moralische Grenzen

überschreiten, beispielsweise weil ihre Entscheidungen auf konfliktären Wertesystemen basieren, wird als Gefahr gesehen.⁷⁴ ML-Anwendungen können auch die soziale Teilhabe der Bürger beeinflussen, wie durch die zunehmend automatisierte Bewerberauswahl für Vorstellungsgespräche. Nicht zuletzt sollten soziale Fragen, wie beispielsweise zu den Auswirkungen des zunehmenden Einsatzes von ML-Verfahren auf den Arbeitsmarkt und unseren Alltag, gesellschaftlich breit diskutiert werden, sowohl hinsichtlich ihrer Chancen als auch ihrer Risiken.⁷⁵ Dezierte öffentliche Foren für die Auseinandersetzung mit möglichen Vorbehalten oder Sorgen vor einem Verlust der menschlichen Entscheidungshoheit durch ML und KI können den Anfang bilden.⁷⁶ Sie sollten helfen, mögliche Vorbehalte der Endverbraucher von Beginn an zu berücksichtigen, und so langfristig zur Akzeptanz ML-basierter Produkte und Dienstleistungen beitragen.

71 Burgess, M., 2017

72 Fachforum Autonome Systeme im Hightech-Forum, 2017

73 Heckmann, D.; Schmid, A., 2017

74 National Science and Technology Council, 2016b

75 Vieth, Kilian, Wagner, Ben im Auftrag der Bertelsmann Stiftung, 2017

76 The Royal Society, 2017

7 FAZIT

Maschinelles Lernen und Künstliche Intelligenz sind inzwischen zu einem wirtschaftlich, gesellschaftlich und strategisch hochrelevanten Thema geworden. Ihr Einsatz wird in immer mehr Anwendungsgebieten wettbewerbsentscheidend sein. Insbesondere die USA und China gehören zu den stärksten Wettbewerbern. Somit rücken Fragen zu Forschung und Entwicklung, geeignetem Personal, verfügbaren Daten und kommerziellen Anwendungen immer stärker in den Fokus der Politik, Wissenschaft und Wirtschaft in Deutschland.

Die Publikationsstatistiken zeigen, dass die Forschung zu ML in Deutschland gut aufgestellt ist. Allerdings bestehen Defizite bei der wertschöpfenden Umsetzung der wissenschaftlichen Errungenschaften im Markt. Dies spiegelt sich in den vergleichsweise geringen Patentanmeldungen Deutschlands wider und ebenso in der geringen Präsenz von KMU in dem Bereich. Auch von den konsultierten Fachleuten wurde betont, dass der Transfer in die Praxis unbedingt gestärkt werden muss. Hierzu wurden gezielte Transferprojekte in Kooperation zwischen Grundlagenforschung und Anwendung als Möglichkeit vorgeschlagen.

Die Expertinnen und Experten warnen, dass die fehlenden spezialisierten Daten-, ML- und KI-Fachkräfte die Wettbewerbsfähigkeit Deutschlands ernsthaft gefährden. Hierbei geht es nicht allein um die benötigte Menge an Fachkräften, sondern auch um die Breite ihrer Ausbildung, um ML-Techniken für die Bedarfe der Industrie einzusetzen.

Der Zugang zu Daten und ihr kontrollierter Austausch sind essenziell in einem Kontext, wo datengetriebenes Vorgehen wettbewerbsentscheidend ist. Den Fachleuten zufolge ist Datenverfügbarkeit momentan eine Herausforderung für Deutschland. Dies erfordert Governance-Modelle, die Anreize schaffen, Daten mit anderen Akteuren für wissenschaftliche und wirtschaftliche Zwecke auszutauschen, ohne dass hier Kontrollverlust und Datenschutzbedenken auftreten.

Bei neuen, von vielen als disruptiv erachteten Technologien wie ML und KI müssen frühzeitig Chancen und mögliche Vorbehalte berücksichtigt und breit diskutiert werden. Denn Anwendungen, die rechtliche Herausforderungen, aber auch ethische Vorstellungen und das Bedürfnis nach Sicherheit und Transparenz adressieren, tragen zum Erfolg auf dem heimischen Markt bei und so mittelbar auch zur globalen Wettbewerbsfähigkeit Deutschlands.

GLOSSAR

Adversarial Learning oder gegnerisches Lernen	Beim gegnerischen Lernen wird versucht, ein Modell durch Lernen mit sogenannten gegnerischen Beispielen (Englisch: Adversarial Examples) robuster gegenüber Angriffen zu machen. »Adversarial Examples« sind absichtlich gestört, um gezielt falsche Ergebnisse herbeizuführen.
Auto-ML, automatisiertes Maschinelles Lernen	Auto-ML steht für »automatisiertes Maschinelles Lernen« und bezeichnet Verfahren zur Unterstützung von Data Scientists, die automatisch den Datenanalyseprozess aufsetzen, inklusive der Schritte zum Maschinellen Lernen.
Algorithmus, Lernalgorithmus	In der Informatik ist ein Algorithmus eine genaue Berechnungsvorschrift zur Lösung einer Aufgabe. Ein Lernalgorithmus ist ein Algorithmus, der Beispieldaten (Lerndaten oder Trainingsdaten) erhält und ein Modell für die gesehenen Daten berechnet, das auf neue Beispieldaten verallgemeinert.
Bestärkendes Lernen oder Reinforcement Learning	Beim bestärkenden Lernen erhält der Lernalgorithmus gelegentliches Feedback für Interaktionen mit der Umwelt und lernt, die Erfolgsaussichten der einzelnen Aktionen in den verschiedenen Situationen besser einzuschätzen.
Bild- und Videoanalyse	Bei der Bild- und Videoanalyse werden visuelle Daten von optischen Sensoren und Kamerasystemen verarbeitet, um Objekte, Szenen und Aktivitäten in der Umgebung wahrzunehmen und identifizieren.
Black-Box-, White-Box-, Grey-Box-Modelle	Black-Box-Modelle des Maschinellen Lernens sind Modelle rein statistischer Art. White-Box-Modelle dagegen bezeichnen analytische und physikalische Beschreibungen, deren Modellierung meist sehr aufwändig ist. Bei Grey-Box-Modellen kombiniert man beide Ansätze, um die jeweiligen Vorteile zu vereinen.
Bot	Unter einem Bot versteht man ein Computerprogramm, das weitgehend automatisch wiederkehrende Aufgaben abarbeitet. Beispiele, die vom Maschinellen Lernen profitieren könnten, sind Chatbots, Social Bots und Gamebots.
Tiefes Lernen oder Deep Learning (DL)	Tiefes Lernen bedeutet das Lernen in Künstlichen Neuronalen Netzen mit mehreren bis sehr vielen inneren Schichten. Tiefes Lernen ist verantwortlich für die Erfolge in der Sprach- und Text-, Bild- und Videoverarbeitung.
Echtzeit	Echtzeit bedeutet die ständige Betriebsbereitschaft eines Systems, bei der alle Reaktionen und Rechenschritte in einer bestimmten kurzen Zeitspanne ablaufen.

Ende-zu-Ende Lernen	Beim Ende-zu-Ende-Lernen werden alle nötigen Zwischenschritte von Eingabe zu Ausgabe innerhalb eines Modells integriert.
Erklärbare KI	Black-Box-Modelle, wie insbesondere die tiefen Künstlichen Neuronalen Netze, sind für Menschen nicht nachvollziehbar. Die »Erklärbare KI« sucht nach Möglichkeiten, die versteckte Logik oder die einzelnen Ausgaben besser nachvollziehbar oder erklärbar zu machen.
KI-gestützte Sensordatenfusion	Bei der KI-gestützten Sensordatenfusion werden verschiedene Sensortypen zusammengeführt und statistisch gegenseitige Abhängigkeiten zwischen unterschiedlichen Datenquellen gelernt.
Klassische Lernverfahren, traditionelle Lernverfahren	Zu den klassischen oder traditionellen Lernverfahren gehören symbolische Verfahren und ältere statistische Verfahren. Nicht dazu zählen Verfahren für tiefe Neuronale Netze.
Kognitive Maschinen oder kognitive Systeme	Kognitive Maschinen oder Systeme sind alternative Begriffe für künstliche intelligente Systeme. Sie zeichnen sich aus durch Fähigkeiten des Lernens und Schlussfolgerns sowie der Sprachverarbeitung, Bildverarbeitung und Interaktion mit dem Nutzer.
Künstliche Intelligenz (KI)	Künstliche Intelligenz ist ein Teilgebiet der Informatik mit dem Ziel, Maschinen zu befähigen, Aufgaben »intelligent« auszuführen. Dabei ist weder festgelegt, was »intelligent« bedeutet, noch welche Technik zum Einsatz kommen.
Label	Ein Label, auch Zielmerkmal, markiert die korrekte Antwort zu einem Beispiel. Überwachte Lernverfahren lernen durch Verallgemeinerung Modelle, die auch neuen Beispielen eine Antwort zuordnen. Oft müssen Labels von Menschen vergeben werden.
Künstliche Neuronale Netze (KNN)	Künstliche Neuronale Netze sind Modelle des Maschinellen Lernens, die durch Aspekte des menschlichen Gehirns motiviert wurden. Sie bestehen aus vielen in Software realisierten Schichten von Knoten, die als künstliche Neuronen bezeichnet werden. Der Lernalgorithmus verändert die Gewichte, das sind Zahlenwerte an den Verbindungen zwischen den Knoten, solange, bis die Ergebnisse für die Aufgabe gut genug sind.
Maschinelles Lernen (ML)	Maschinelles Lernen bezweckt die Generierung von »Wissen« aus »Erfahrung«, indem Lernalgorithmen aus Beispielen ein komplexes Modell entwickeln. Das Modell kann anschließend auf neue, potenziell unbekannte Daten derselben Art angewendet werden. Damit kommt das Maschinelle Lernen ohne manuelle Wissensangabe oder explizite Programmierung eines Lösungswegs aus.

Maschinelles Lernverfahren, Lernmethode	Die Begriffe »maschinelles Lernverfahren« und »Lernmethode« werden hier synonym verwendet. Sie beschreiben auf einer abstrakteren Ebene eine Vorgehensweise, die oft durch mehrere konkrete Lernalgorithmen realisiert werden kann.
Multimodales Lernen	Beim multimodalen Lernen werden Eingabesignale von unterschiedlichen Quellen (wie Audio- und Bildsignale) herangezogen und in Zusammenhang gebracht, um darauf aufbauend eine passende Aktion zur Bewältigung der Aufgabe abzuleiten.
Lernstile und Lernaufgaben	Lernstile unterscheiden sich in der Zusatzinformation und den dadurch möglichen Lernaufgaben. Die wichtigsten Lernstile sind überwachtes Lernen, unüberwachtes Lernen und bestärkendes Lernen. Je nachdem, welche Zusatzinformation zur Verfügung steht, können andere Lernaufgaben gelernt werden.
Modell	Ein Modell ist eine Abstraktion der Wirklichkeit. Im Maschinellen Lernen erzeugt der Lernalgorithmus ein Modell, das Beispieldaten generalisiert, so dass es anschließend auch auf neue Daten angewendet werden kann.
Multitask-Lernen	Beim Multitask-Lernen wird versucht, verschiedene Aufgaben gleichzeitig auf einer gemeinsamen internen Repräsentation zu lernen, die dadurch tragfähiger wird.
One-Shot-, Zero-Shot-Lernen	Idealerweise soll anhand weniger Beispiele einer Klasse oder ausschließlich durch die Kombination bekannter Beispiele anderer Klassen automatisch gelernt werden. Diese Fähigkeit in ML-Anwendungen zu implementieren, wird als »One-Shot« – oder gar »Zero-Shot«-Lernen bezeichnet.
Online-Lernen, Lernen auf Datenströmen	Das Online-Lernen kommt ohne die konventionelle Einteilung in Trainingsdaten für die Modellentwicklung und Testdaten für die Modellbewertung aus. Online-Lernen funktioniert also in Echtzeit und auf Datenströmen, die nicht abgespeichert werden.
Quantencomputer	Quantencomputer basieren ihre elementaren Rechenschritte auf quantenmechanischen Zuständen – sogenannte Qubits – anstelle der binären Zustände (Bits) in digitalen Computern und verarbeiten sie gemäß quantenmechanischer Prinzipien. Hierdurch wird für manche Anwendungen ein enormer Geschwindigkeitsvorteil erwartet.
Repräsentationen, Lernen von Repräsentationen	Repräsentationen sind Darstellungen der Daten, die in subsymbolischen Modellen aus vielen Zahlenwerten bestehen. Beispielsweise kann das Bild eines Gesichtes durch alle Pixelwerte repräsentiert werden, oder durch die Angabe von Ort und Größe von Auge, Nase, Mund, usw. Beim Repräsentationslernen werden durch Transformation der Eingabe kompaktere Repräsentationen gelernt, die die eigentliche Lernaufgabe erleichtern.

Subsymbolisch	In subsymbolischen Modellen, wie Künstlichen Neuronalen Netzen, sind die Merkmale der Beispiele und die erlernten Zusammenhänge in vielen Zahlen versteckt, die keinen Einblick in die erlernten Lösungswege erlauben.
Symbolisch	In symbolischen Modellen sind die Merkmale der Beispiele und die erlernten Zusammenhänge explizit und nachvollziehbar repräsentiert. Beispiele sind logische Regeln, Entscheidungsbäume und Wissensgraphen.
Text- und Sprachverarbeitung oder Natural Language Processing (NLP)	Text- und Sprachverarbeitung umfassen Techniken zur Interpretation und Erzeugung von natürlicher Sprache in Wort und Schrift. Dazu gehören die Vertextung gesprochener Sprache, Stimmungserkennung, Informationsextraktion aus Texten, maschinelle Übersetzung und das Führen von Gesprächen.
Transfer-Lernen	Das Transfer-Lernen zielt darauf ab, in einem Künstlichen Neuronalen Netz Teilbereiche zu finden, die bereits für eine bestimmte Aufgabe trainiert worden sind, um sie für eine andere, verwandte Aufgabe wieder zu verwenden.
Überwachtes Lernen oder supervised learning	Beim überwachten Lernen müssen die richtigen Antworten als »Labels« mitgeliefert werden. Damit lassen sich Klassifikations- und Regressionsaufgaben lernen, bei denen Beispiele ihren jeweiligen Labels zugeordnet werden.
Unüberwachtes Lernen oder unsupervised learning	Beim unüberwachten Lernen gibt es nur die rohen Beispieldaten, ohne Labels oder Feedback. Damit können vereinfachende Beschreibungen der gesamten Beispielmenge gefunden werden. So können Daten in verschiedene Gruppen oder Cluster unterteilt oder die Dimensionen, also die Anzahl der Merkmale reduziert werden.
Wissensgraph	Wissensgraphen bestehen aus Knoten und Verbindungen, die symbolisches Wissen über Objekte und ihre Beziehungen repräsentieren. Die Knoten haben einen Typ, beispielsweise Tier, Möbel, Stadt, der die zulässigen Objekte und ihre Beziehungen einschränkt.

QUELLENVERZEICHNIS

Austin, T.; Krensky, P. (2017): Machine Learning/AI: Hard Facts, Conclusions and Actions. Webinar. Gartner, 2017.

Bitkom (Hg.) (2016): Germany – Excellence in Big Data. Unter Mitarbeit von Mathias Weber et al. Berlin, zuletzt geprüft am 20.02.2018

Bitkom (Hg.) (2017): Künstliche Intelligenz verstehen als Automation des Entscheidens, Berlin.

Böttcher, B.; Schwalm, A.-L.; Velten, C. (2017): Machine Learning Anbieter & Dienstleister im Vergleich. Hg. v. Crisp Research.

Burger, R.; Wheelock, C. (2017): Computer Vision Report. Market Trends, M&A Transactions, Private Placement Financings, and Public and Private Company Profiles. Hg. v. Woodside Capital Partners und Tractica.

Burgess, M. (2017): NHS DeepMind deal broke data protection law, regulator rules. In: Wired UK. Online verfügbar unter <http://www.wired.co.uk/article/google-deepmind-nhs-royal-free-ico-ruling>, zuletzt geprüft am 20.02.2018.

Button, R. W. (2017): Artificial Intelligence and the Military. RealClearDefense. Online verfügbar unter <https://www.rand.org/blog/2017/09/artificial-intelligence-and-the-military.html>, zuletzt geprüft am 20.02.2018.

Campolo, A.; Sanfilippo, M.; Whittaker, M.; Crawford, K. (2017): AI Now 2017 Report. Hg.: AI NOW.

De Spiegeleire, S.; Maas, M.; Sweijs, T. (2017): Artificial Intelligence and the future of defense: Strategic implications for small- and medium-sized force providers. <https://www.hcss.nl/sites/default/files/files/reports/Artificial%20Intelligence%20and%20the%20Future%20of%20Defense.pdf>, zuletzt geprüft am 20.02.2018.

Economist (2016): Million-dollar babies. As Silicon Valley fights for talent, universities struggle to hold on to their stars. Artificial intelligence. Online verfügbar unter <https://www.economist.com/news/business/21695908-silicon-valley-fights-talent-universities-struggle-hold-their>, zuletzt geprüft am 20.02.2018.

EFI-Expertenkommission Forschung und Innovation (2018): Gutachten zu Forschung, Innovation und technologischer Leistungsfähigkeit Deutschlands 2018, Berlin: EFI: S 79-80.

Evtimov, I. et al. (2017): Robust Physical-World Attacks on Deep Learning Models. <https://arxiv.org/abs/1707.08945>, zuletzt geprüft am 20.02.2018.

Fachforum Autonome Systeme im Hightech-Forum (2017): Autonome Systeme – Chancen und Risiken für Wirtschaft, Wissenschaft und Gesellschaft. Kurzversion, Abschlussbericht, Berlin, März 2017. S. 22.

Fraunhofer-Gesellschaft (2017): Industrial Data Space – White Paper. https://www.fraunhofer.de/content/dam/zv/de/Forschungsfelder/industrial-data-space/Industrial-Data-Space_whitepaper.pdf, zuletzt geprüft am 25.05.2018.

Gartner (Hg.) (2017): Hype Cycle for Data Science and Machine Learning. Unter Mitarbeit von Peter Krensky und Jim Hare.

Gentsch, P. (2018): Künstliche Intelligenz für Sales, Marketing und Service. Mit AI und Bots zu einem Algorithmic Business - Konzepte, Technologien und Best Practices. Wiesbaden: Springer Gabler.

Groopman, J.; Kaul, A. (2017): Deep Learning. Enterprise, Consumer, and Government Applications for Deep Learning Software, Hardware, and Services: Market Analysis and Forecasts for 112 Use Cases. Research Report. Hg. v. Tractica.

Groopman, J.; Wheelock, C. (2017): Artificial Intelligence: 10 Key Themes Across Use Cases. White Paper. Hg. v. Tractica.

He, K. et al. (2015): Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification. <https://arxiv.org/pdf/1502.01852v1.pdf>, zuletzt geprüft am 20.02.2018.

Heckmann, D.; Schmid, A. (2017): Rechtliche Aspekte automatisierter Systeme. Rechtskonforme Gestaltung unserer Zukunft. In: Informatik Spektrum (5/2017).

Kaggle (2017): The State of Data Science & Machine Learning 2017 <https://www.kaggle.com/surveys/2017>, zuletzt geprüft am 20.02.2018.

KDnuggets.com (Hg.) (2016): Datasets Over Algorithms <https://www.kdnuggets.com/2016/05/datasets-over-algorithms.html>, zuletzt geprüft am 20.02.2018.

Kirkpatrick, J. et al. (2017): Overcoming catastrophic forgetting in neural networks. <http://www.pnas.org/content/114/13/3521.full>, zuletzt geprüft am 20.02.2018.

Lakemeyer, G. (2017): Künstliche Intelligenz. Analysen & Argumente - Digitale Gesellschaft, Ausgabe 261, Hg.: Konrad Adenauer Stiftung. Berlin.

Matsakis, L. (2017): Researchers Fooled a Google AI Into Thinking a Rifle Was a Helicopter. <https://www.wired.com/story/researcher-fooled-a-google-ai-into-thinking-a-rifle-was-a-helicopter/>, zuletzt geprüft am 20.02.2018.

McKinsey (Hg.) (2017): Smartening up with Artificial Intelligence (AI). What's in it for Germany and its Industrial Sector? (Digital).

McKinsey Global Institute (2017): Artificial Intelligence, the next digital frontier? Discussion Paper, Juni 2017.

Mnih, V. et al. (2015): Human-level control through deep reinforcement learning. Nature. 518, 529- 541.

National Science and Technology Council (2016a): Preparing for the future of artificial intelligence. Online verfügbar unter: https://obamawhitehouse.archives.gov/sites/default/files/whitehouse_files/microsites/ostp/NSTC/preparing_for_the_future_of_ai.pdf, zuletzt geprüft am 20.02.2018.

National Science and Technology Council (2016b): The National Artificial Intelligence Research and Development Strategic Plan. Online verfügbar unter https://www.nitrd.gov/PUBS/national_ai_rd_strategic_plan.pdf, zuletzt geprüft am 20.02.2018.

Neuhäusler, P. Frietsch, R. Rothengatter, O. (2015): Patentierung computerimplementierter Erfindungen – Aktuelle Rechtslage und ökonomische Implikationen, Fraunhofer ISI Discussion Papers No. 46

OECD (2016): Summary of the CDEP Technology Foresight Forum: Economic and Social Implications of Artificial Intelligence, presentation materials of Professor Dr Susumu Hirano and Associate Professor Tatsuya Kurosaka, OECD, Paris.

OECD (2017): Digital Economy Outlook 2017, S. 306.

PwC (Hg.) (2017): Datenaustausch als wesentlicher Bestandteil der Digitalisierung.

Rao, A. S.; Verweij, G. (2017): Sizing the prize. What's the real value of AI for your business and how can you capitalise? Hg. v. PWC.

Sahi, M. K.; Kaul, A. (2017): Customer Service Robots. Humanoid and Non-Humanoid Robots for Retail, Travel and Hospitality, Financial Services, Restaurants, Healthcare, and Other Customer-Facing Applications: Global Market Analysis and Forecasts. Executive Summary. Hg. v. Tractica.

Simonite, T. (2017): For Superpowers, Artificial Intelligence Fuels New Global Arms Race. Wired Business. Online verfügbar unter <https://www.wired.com/story/for-superpowers-artificial-intelligence-fuels-new-global-arms-race/>, zuletzt geprüft am 20.02.2018.

Stanford University (Hg.) (2016): Artificial Intelligence and Life in 2030. One Hundred Year study on Artificial Intelligence. Report of the 2015-2016 Study Panel. Unter Mitarbeit von Peter Stone, Rodney Brooks, Erik Brynjolfsson, Ryan Calo, Oren Etzioni, Greg Hager, Julia Hirschberg, Shivaram Kalyanakrishnan, Ece Kamar, Sarit Kraus, Kevin Leyton-Brown, David Parkes, William Press, AnnaLee Saxenian, Julie Shah, Milind Tambe, and Astro Teller. Online verfügbar unter <http://ai100.stanford.edu/2016-report>, zuletzt geprüft am 20.02.2018.

Stifterverband, McKinsey (Hg.) (2017): Hochschulbildungsreport 2020 - Höhere Chancen durch höhere Bildung. Jahresbericht 2017/18 – Halbzeitbilanz 2010 bis 2015: 70-74.

The Royal Society (2017): Machine learning: the power and promise of computers that learn by example. S. 89 ff.

Tractica (Hg.) (2017): Deep Learning. Enterprise, Consumer, and Government Applications for Deep Learning Software, Hardware, and Services: Market Analysis and Forecasts for 112 Use Cases.

Valorge, S.; Combaudou, O.; Chastel, T.; Lyet, M.; Vasco, A. (2017): Artificial Intelligence. From Hype to Maturity? Hg. v. Clipperton.

VDMA (2017): Machine Learning 2030. Zukunftsbilder für den Maschinen- und Anlagenbau/Band 1. S. 24 ff.

Verband der Automobilindustrie e.V. (Hg.) (2015): Automatisierung. Von Fahrerassistenzsystemen zum automatisierten Fahren. Berlin. Online verfügbar unter www.vda.de.

Vieth, K., Wagner, B. im Auftrag der Bertelsmann Stiftung (2017): Teilhabe, ausgerechnet - Wie algorithmische Prozesse Teilhabechancen beeinflussen können.

WEITERFÜHRENDE LITERATUR ZUM THEMA MASCHINELLES LERNEN

Bishop, Christopher M. (2007): Pattern Recognition and Machine Learning (Information Science and Statistics). Springer

Downey, Allen B. (2011): Think Stats: Probability and Statistics for Programmers. Green Tea Press Needham, Massachusetts
<http://greenteapress.com/thinkstats/thinkstats.pdf>

Ertel, Wolfgang (2016): Grundkurs Künstliche Intelligenz. Springer

Géron, Aurélien (2017): Praxiseinstieg Machine Learning mit Scikit-Learn und TensorFlow: Konzepte, Tools und Techniken für intelligente Systeme (Animals). O'Reilly

Goodfellow, Ian; Bengio, Yoshua; Courville, Aaron (2016): Deep Learning. MIT Press

Hastie, Trevor; Tibshirani, Robert; Friedman, Jerome (2009): The Elements of Statistical Learning. Springer

Ng, Andrew (2016): Machine Learning Yearning.

Rashid, Tariq; Langenau, Frank (2017): Neuronale Netze selbst programmieren: Ein verständlicher Einstieg mit Python. O'Reilly

Shai, Shalev-Shwartz; Shai, Ben-David (2014): Understanding Machine Learning: From Theory to Algorithms. Cambridge University Press

Wartala, Ramon (2017): Praxiseinstieg Deep Learning: Mit Python, Caffe, TensorFlow und Spark eigene Deep-Learning-Anwendungen erstellen. O'Reilly

ABBILDUNGEN UND TABELLEN

Abbildung 1: Verwendete Methoden der von Kaggle befragten Data Scientists und ML-Fachleute	11
Abbildung 2: Schematische Darstellung eines KNN, hier in Form eines Feed-forward Network, eigene Darstellung	12
Abbildung 3: Schematische Darstellung eines Entscheidungsbaums	12
Abbildung 4: Entwicklung der Publikationen im Bereich ML für Deutschland (DE), Frankreich (FR), Großbritannien (UK), USA (US) und China (CN) sowie die restlichen EU-Staaten und übrige Länder	14
Abbildung 5: Anteil der Deep Learning Publikationen an gesamten ML-Publikationen, 2006-2016	16
Abbildung 6: Kompetenzlandkarte auf Basis wissenschaftlicher Publikationen, 2006-2016	17
Abbildung 7: Entwicklung der Patentfamilien zu ML-Technologie nach Ländern, 2006-2015	20
Abbildung 8: Anzahl der deutschen Unternehmen mit Patentaktivitäten	22
Abbildung 9: Entwicklung der Patentfamilien für ML-Anwendungsbereiche, 2006-2015	22
Abbildung 10: Anwendungsbranchen für Maschinelles Lernen	26
Tabelle 1: Überblick zu ausgewählten Meilensteinen im Einsatz von Maschinellern Lernen	9
Tabelle 2: Gängige Lernverfahren und ihre Modelle	10
Tabelle 3: Top-10 der publikationsstärksten Akteure weltweit	15
Tabelle 4: Anzahl der ML-Publikationen in Unternehmen	17
Tabelle 5: Die publikationsstärksten Forschungseinrichtungen Deutschlands im Bereich ML	18
Tabelle 6: Führende Einrichtungen nach Patentierung in ML-Anwendungsbereichen, 2006-2015	21
Tabelle 7: Führende Einrichtungen ML-Anwendungsbereiche in Deutschland, 2006-2015	21
Tabelle 8: ML-Patentfamilien nach Anwendungsbereichen, 2006-2015	23
Tabelle 9: Zukünftige Forschungsthemen und die Bewertung der Fachleute	28
Tabelle 10: ML-basierte Kompetenzen, Forschungsansätze, Einsatzgebiete und Reifegrad	32

DANKSAGUNG

Wir bedanken uns bei allen Expertinnen und Experten, die für ein Interview zur Verfügung gestanden oder an dem wissenschaftlichen Validierungsworkshop am 29.11.2017 in Berlin teilgenommen haben, sowie den Mitwirkenden aus den Bundesministerien.

Experteninterview:

- | Prof. Dr.-Ing. habil. Jürgen Beyerer, Fraunhofer IOSB und KIT
- | Alexander Fabisch, DFKI GmbH
- | Prof. Dr. Johannes Fürnkranz, Technische Universität Darmstadt
- | Eberhard Hechler, IBM Deutschland Research & Development GmbH
- | Prof. Dr. Eyke Hüllermeier, Universität Paderborn
- | Ralf Klinkenberg, RapidMiner GmbH
- | Dr. Melanie Knapp, ITyX Solutions AG
- | Prof. Dr. Katharina Morik, Technische Universität Dortmund
- | Dr. Michael May, Siemens AG
- | Prof. Claus Oetter, VDMA
- | Marc Otto, AG Robotik, Universität Bremen
- | Prof. Dr. Martin Riedmiller, DeepMind
- | Manuel Pereira Remelhe, Bayer AG
- | Prof. Dr. Stefan Wrobel, Fraunhofer IAIS

Validierungsworkshop:

- | Felix Assion, neurocat GmbH
- | Dr. Tarek Besold, City, University of London
- | Prof. Dr.-Ing. habil. Jürgen Beyerer, Fraunhofer IOSB und KIT
- | Dr. Daniel Büscher, Universität Freiburg
- | Peter Deussen, Microsoft Deutschland GmbH
- | Florens Greßner, neurocat GmbH
- | Prof. Dr. Horst-Karl Hahn, Fraunhofer MEVIS und Jacobs University Bremen
- | Matthias Himmer, Salesforce, Einstein Analytics EMEA Central
- | Dr. Christoph Kehl, Büro für Technikfolgen-Abschätzung beim Deutschen Bundestag (TAB)
- | Dr. Anna-Lena Kranz-Stöckle, Bundesministerium für Bildung und Forschung
- | Andrea Martin, IBM Deutschland GmbH
- | Dr. Christian Reisswig, SAP SE, Deep Learning Center of Excellence
- | Catrin Schaefer, Bundesministerium für Gesundheit
- | Dr. Matthias Schulz, Projektträger des DLR
- | Dr. Michael Weber, Bundesministerium für Bildung und Forschung
- | Dr. Stefan Wess, Empolis Information Management GmbH
- | Dr. Steffen Wischmann, Institut für Innovation und Technik in der VDI/VDE-IT GmbH

Unser Dank gilt auch den Expertinnen und Experten, die nicht namentlich erwähnt werden wollten.

IMPRESSUM

Herausgeber

Fraunhofer-Gesellschaft zur Förderung der angewandten Forschung e.V.

Beteiligte Institute

**I Fraunhofer-Institut für
Intelligente Analyse- und
Informationssysteme IAIS**
Schloss Birlinghoven
53757 Sankt Augustin

Telefon: +49 2241 14-2252
www.iais.fraunhofer.de

**I Fraunhofer-Zentrum für
Internationales Management
und Wissensökonomie IMW**
Neumarkt 9-19
04109 Leipzig

Telefon: +49 341 23 10 39-0
www.imw.fraunhofer.de

**I Zentrale der
Fraunhofer-Gesellschaft**
Hansastraße 27c
80686 München

Telefon: +49 89 12 05-0
www.fraunhofer.de

Coverbild

© sdecoret/Fotolia

Layout und Satz

Kristina Seyffarth, Fraunhofer-Institut für Intelligente
Analyse- und Informationssysteme IAIS, Sankt Augustin

© Fraunhofer-Gesellschaft, München 2018

Die Publikation wurde durch das Bundesministerium
für Bildung und Forschung (BMBF) gefördert.

GEFÖRDERT VOM



Bundesministerium
für Bildung
und Forschung

